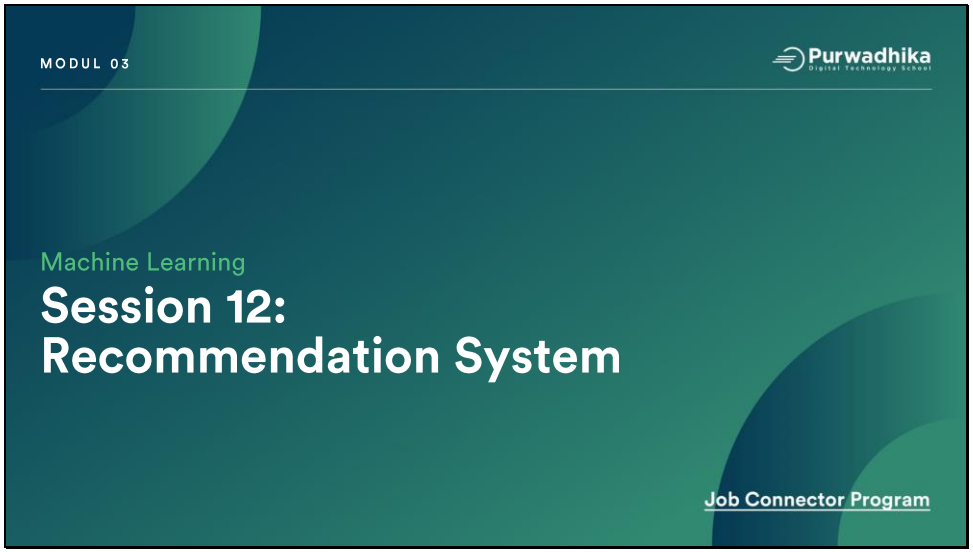
Slide 1


MODUL 03
Purwadhika
Digital Technology School
Machine Learning
Session 12:
Recommendation System
Job Connector Program

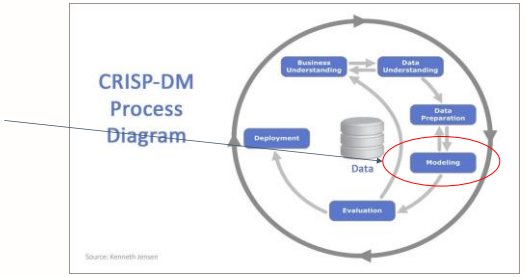
Slide 2

Outline

Purwadhika Digital Technology School

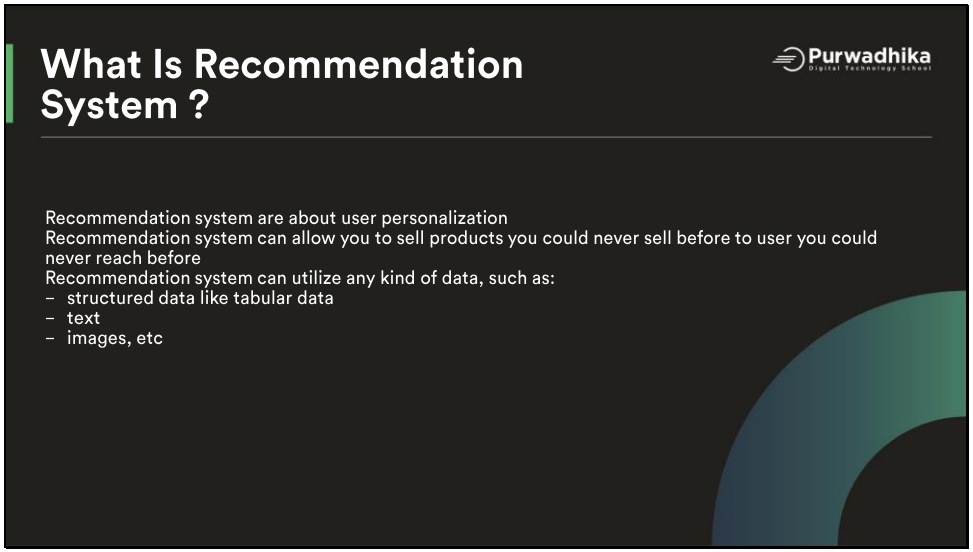
What Is Recommendation System ?
Content based
- similarity measure
- content based filtering

Collaborative Filtering
- memory based
- model based



Kita akan bahas Recommendation System pada sesi ini. Secara garis besar ada dua jenis metode yang akan kita bahas, content based dan collaborative filtering. Metode content based yang akan kita diskusikan ada dua content based dengan similarity measure serta content based filtering. Metode collaborative filtering yang akan kita diskusikan ada dua yaitu memory based dan model based.

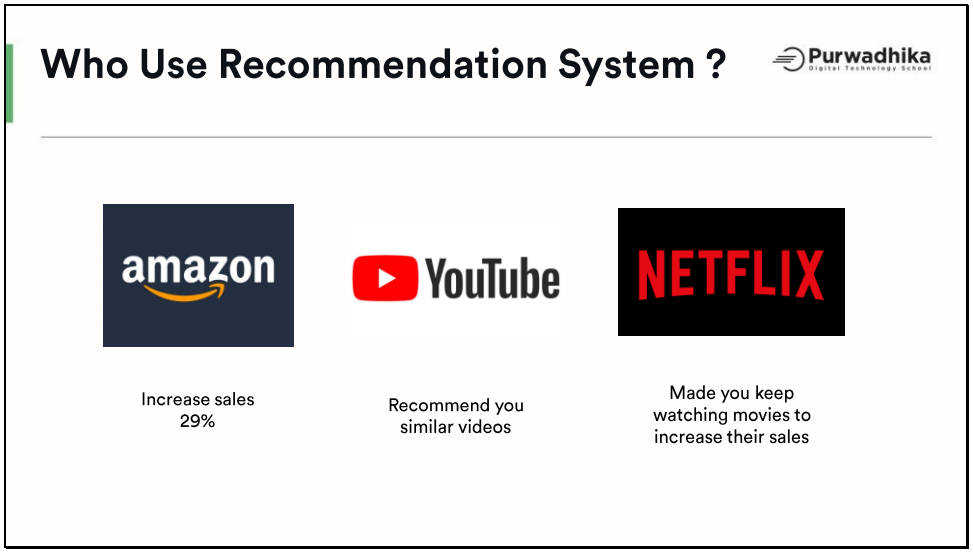
Slide 3



WHAT IS RECOMMENDATION SYSTEM ?

Recommendation system berisi tentang personalisasi penggunaan produk atau jasa. Dengan recommendation system, kita dapat menjual suatu produk yang tidak pernah dapat anda jual sebelumnya kepada pengguna yang sebelumnya sulit anda capai. Lebih banyak produk yang terjual tentu akan memberikan income yang lebih besar juga, serta makin banyak pengguna semakin besar juga bisnis yang kita punya. Dalam prakteknya recommendation system dapat memanfaatkan berbagai jenis data. Mulai dari data yang sudah terstruktur hingga data yang tidak terstruktur seperti data teks dan data gambar.

Slide 4



Who uses Recommendation System ?

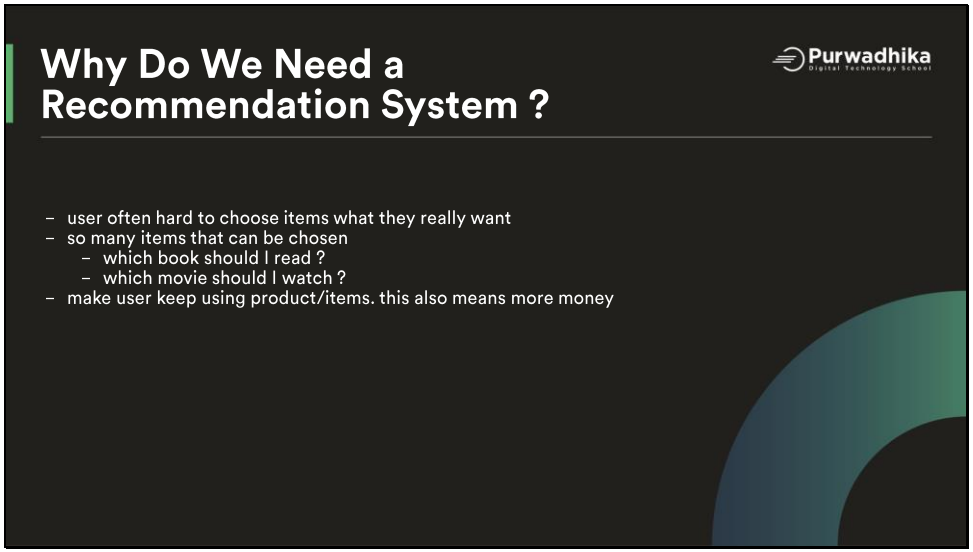
Recommendation system sudah diterapkan di berbagai industri dan terbukti sangat ampuh untuk bisnis. Perusahaan-perusahaan besar seperti Amazon, YouTube dan Netflix menggunakan recommendation system dalam sistem yang mereka punya.

Amazon sendiri sudah melibatkan berbagai macam jenis recommendation system dalam sistem yang mereka punya. Amazon membeberkan fakta bahwa pada suatu ketika mereka pernah mengalami peningkatan penjualan sebesar 29%, dari $9.9 juta dolar ke $12.83 juta dollar.

Ketika anda melihat video dari YouTube, pernahkah anda menonton kumpulan video, kemudian anda menemukan video yang belum pernah anda tonton sebelumnya tapi ternyata video tersebut memiliki kemiripan dengan video-video yang telah anda tonton sebelumnya.

Netflix juga merupakan salah satu perusahaan besar yang menggunakan recommendation system. Pernahkah anda mengobrol dengan teman anda terkait film-film yang anda suka. Kemudian anda dan teman anda akan saling memberitahu film yang akan mungkin disukai. Begitulah salah satu cara netflix merekomendasikan film-filmnya.

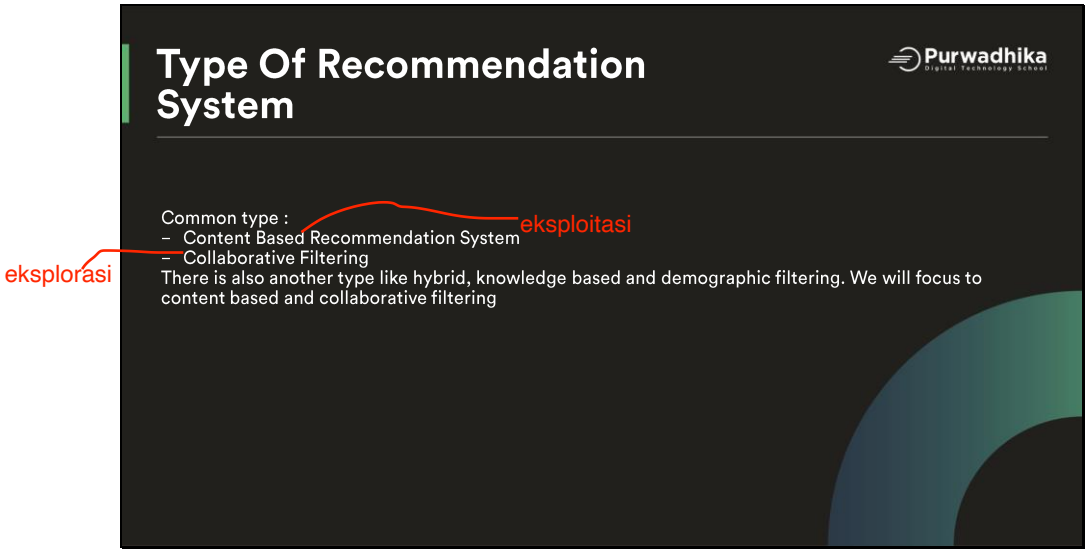
Slide 5



Why Do We Need a Recommendation System ?

Terkait mengapa kita butuh recommendation system, Pengguna seringkali tidak mengetahui apa yang sebenarnya mereka inginkan. Ada banyak sekali pilihan. Misalkan, ketika kita hendak membaca buku, buku mana yang perlu saya baca, Movie mana yang sebenarnya saya ingin lihat dan lain-lain. Dengan bantuan recommendation system kita dapat mempermudah user dalam menentukan pilihan. Pada dasarnya kita ingin user terus menggunakan produk yang kita punya sehingga pada akhirnya keuntungan yang diperoleh pun meningkat.

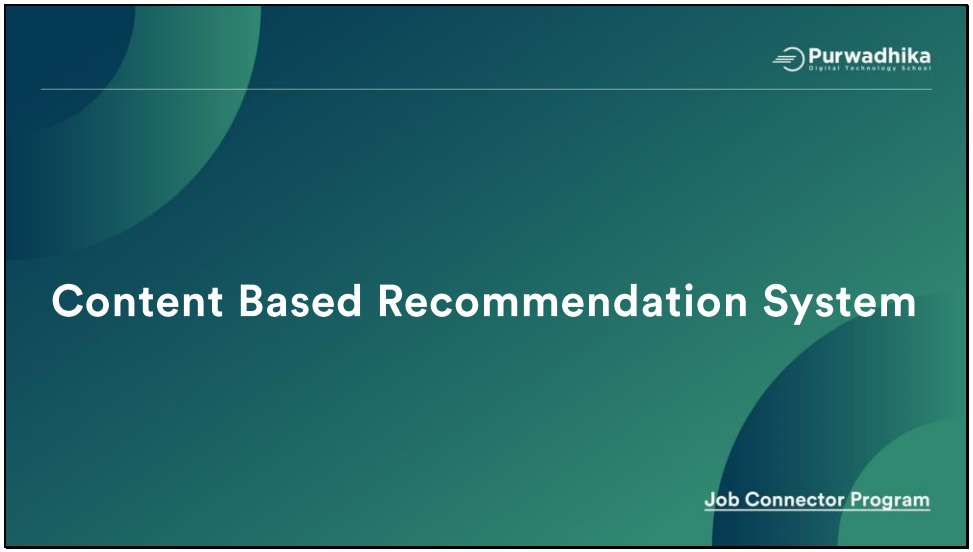
Slide 6



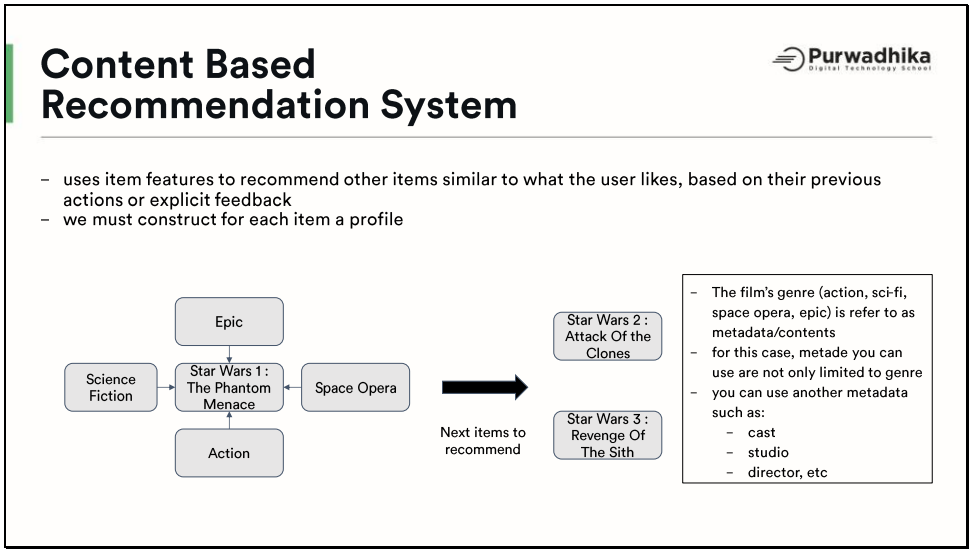
Type Of Recommendation System

Recommendation system ada beberapa jenis, jenis metode yang akan kita bahas adalah Content Based Recommendation System dan Collaborative Filtering. Dengan content based filtering kita melakukan rekomendasi berdasarkan kemiripan items sedangkan collaborative filtering merekomendasikan items berdasarkan user lain yang memiliki preferensi yang mirip. Perlu anda ketahui bahwa kedua jenis metode di atas memiliki kekurangan dan kelebihan masing-masing. Ada juga metode-metode lain seperti hybrid recommendation system, knowledge based dan demographic filtering tapi metode yang akan kita fokuskan adalah content based dan collaborative filtering.

Slide 7


Purwadhika
Digital Technology School
Content Based Recommendation System
Job Connector Program

Slide 8

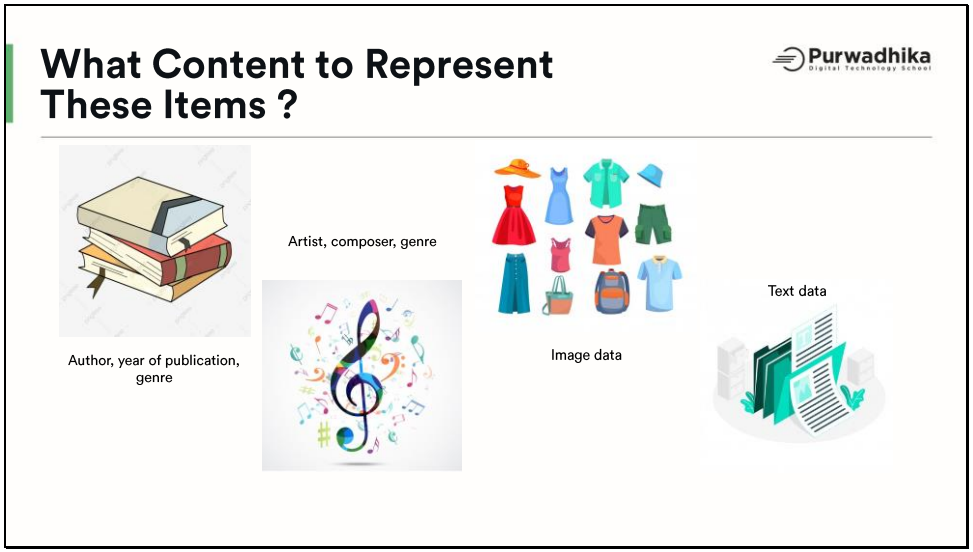


CONTENT BASED RECOMMENDATION SYSTEM

Content based recommendation system merupakan suatu metode yang memberikan rekomendasi produk/items berdasarkan kemiripan dengan produk/items yang disukai. Kita perlu membuat personalisasi atau profil untuk setiap item kemudian mencari items yang memiliki kemiripan profil. Profil dapat dibentuk dari berbagai aspek, misalkan untuk film bisa berdasarkan genrenya. Genre ini lah yang dimaksud dengan konten dalam content based recommendation system. Tentu konten yang dapat digunakan tidak hanya terbatas pada genre. Kita dapat gunakan konten lain seperti siapa pemerannya, studio tempat dibuatnya film, sutradara atau berbagai konten lainnya.

Misalkan ada seorang user yang sudah menonton film star wars 1 : The Phantom Menace. Film tersebut termasuk ke dalam genre Epic, Sci-Fi, action dan space opera. Content based recommendation system akan mencari film dengan genre serupa sebagai rekomendasi untuk tontonan berikutnya. Film-film yang akan direkomendasikan selanjutnya adalah Star Wars 2: Attack Of The Clones dan Star Wars 3: Revenge Of The Sith.

Slide 9



Sekarang kita coba beralih ke masalah recommendation untuk kasus lainnya. Buku memiliki konten yang serupa dengan film. Konten yang dapat kita gunakan untuk membuat profil dari setiap buku diantaranya pengarangnya, tahun publikasinya, dan genrenya.

Jika kita hendak merekomendasikan music dengan content based kita dapat gunakan konten seperti artisnya, komposernya dan juga genrenya.

Untuk barang-lain seperti rekomendasi baju kita dapat gunakan model bajunya sebagai konten untuk membuat recommendation system. Data gambar dari masing-masing baju dapat diekstrak untuk kemudian hasil ekstrasinya dijadikan konten untuk profiling.

Sama halnya dengan item yang berupa artikel, dokumen atau berita. Kita dapat gunakan isi beritanya sebagai konten untuk membuat recommendation system. Konten dari setiap dokumen diekstrak dari data yang berupa text.

Slide 10

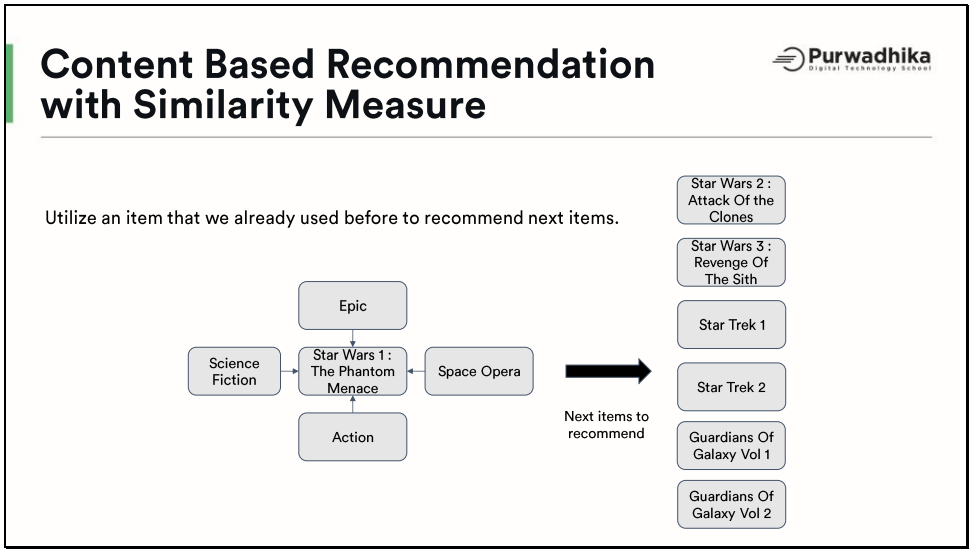


Ada dua metode content based recommendation system yang akan kita bahas yaitu similarity measure dan content based filtering. Pada topik ini kita akan membahas content based recommendation system.

Slide 11


Purwadhika
Digital Technology School
Content Based Recommendation with Similarity Measure
Job Connector Program

Slide 12



Content Based Recommendation System with Similarity Measure

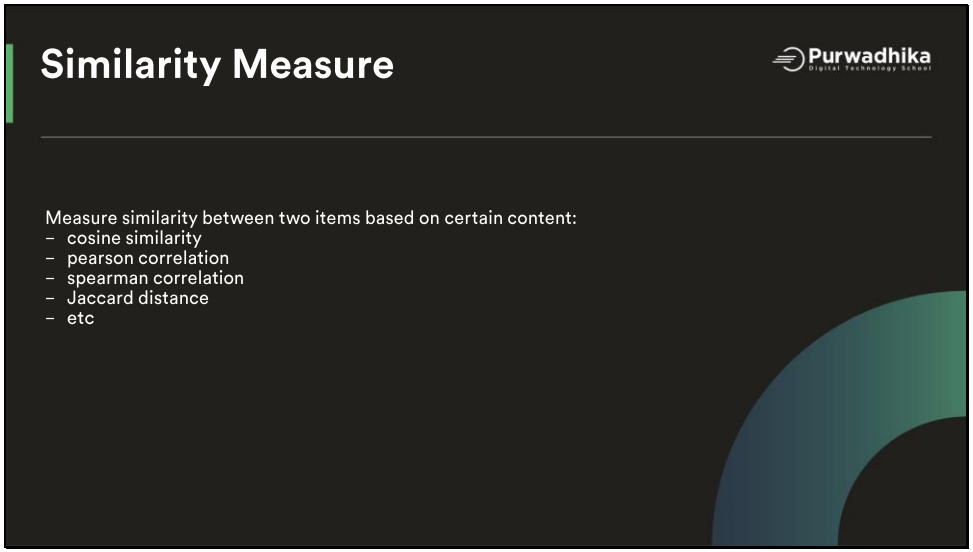
Content based recommendation system memanfaatkan salah satu item yang sudah kita gunakan untuk merekomendasikan item serupa sebagai rekomendasi untuk item berikutnya. Seperti contoh sebelumnya, misalkan kita telah menonton film star wars 1. Jika kita gunakan genre untuk profiling, Content based akan memberikan rekomendasi film-film yang genrenya serupa seperti film-film star wars lainnya, star trek 1, star trek 2, Guardians of Galaxy Vol 1, Guardians Of Galaxy Vol 2 dan film-film lainnya yang serupa.

Slide 13



Contoh lainnya, misalkan saya hendak membeli sebuah earphone di suatu situ online. Content based recommendation system akan memberikan rekomendasi item lainnya yang serupa, yaitu earphone merek lain atau earphone lain yang berbeda tipe.

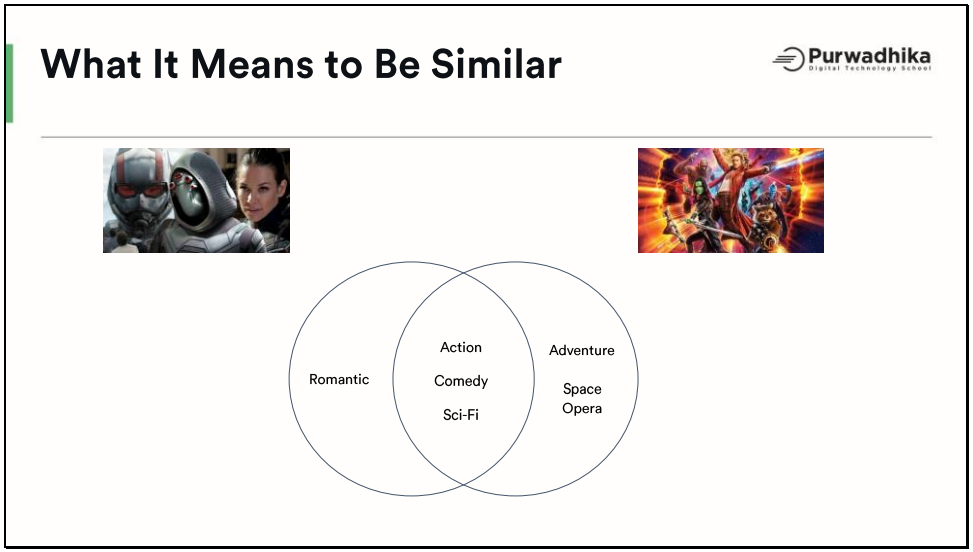
Slide 14



Similarity Measure

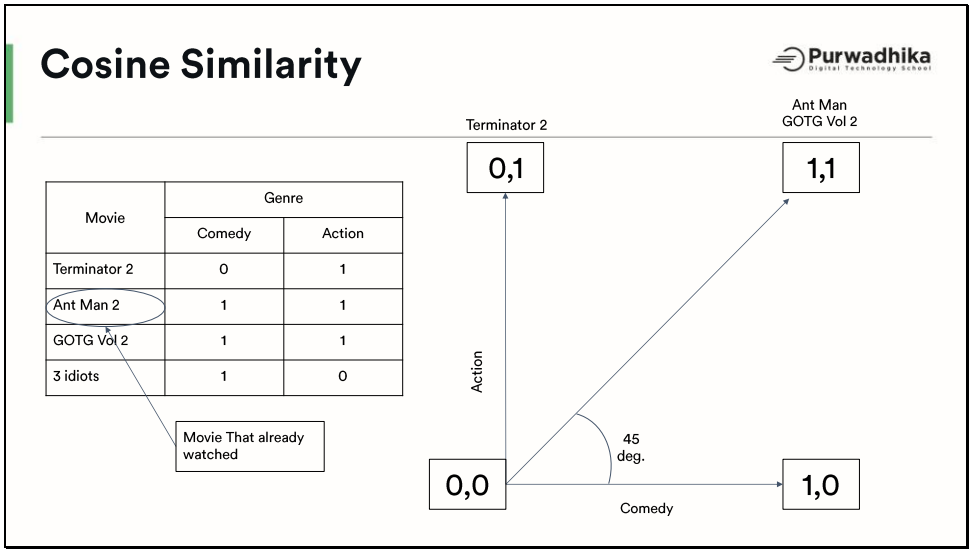
Seperti yang sudah dijelaskan sebelumnya, dalam content based recommendation system kita perlu membuat profil untuk setiap item. Profil dapat dibentuk berdasarkan konten apapun yang sesuai dengan keinginan dan kebutuhan kita. Setelah kita tentukan konten apa yang digunakan kita dapat mengukur kemiripan antar item dengan metode-metode seperti cosine similarity, pearson correlation, spearman correlation, jaccard distance dan lain-lain.

Slide 15



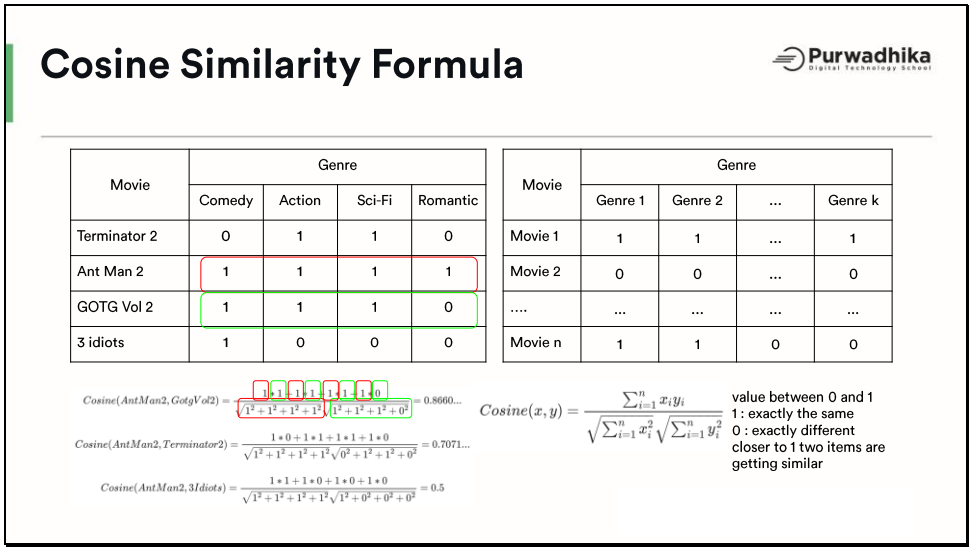
Agar anda mendapat bayangan bagaimana film yang memiliki kemiripan. Perhatikan ilustrasi berikut ini. Kedua film ini pada kenyataan memang memiliki banyak kemiripan dari segi genre. Kedua film memiliki kesamaan dalam genre Action, Comedy dan Sci-Fi. Metode-metode yang sudah disebutkan sebelumnya mampu mengukur dan mampu mengkuantitatifkan seberapa mirip kedua film ini.

Slide 16



Sekarang akan saya ilustrasikan bagaimana cosine similarity bekerja. Katakan lah kita punya empat film dan kita hanya ambil dua genre agar dapat divisualisasikan bagaimana cosine similarity bekerja. Kita plotkan comedy pada sumbu x dan action pada sumbu y. Kita anggap posisi (0,0) sebagai titik pusat, lalu kita posisikan masing-masing film sesuai dengan koordinatnya dan kita tarik garis lurus dari titik pusat ke masing-masing film. Sudut yang terbentuk antara dua film mencerminkan seberapa mirip kedua film tersebut. Semakin kecil sudut semakin mirip pula filmnya dan jika dempet artinya kedua film sama persis dari segi konten. Jika garis antara dua film membentuk sudut siku-siku (90 deg.) maka film itu jelas berbeda.

Slide 17

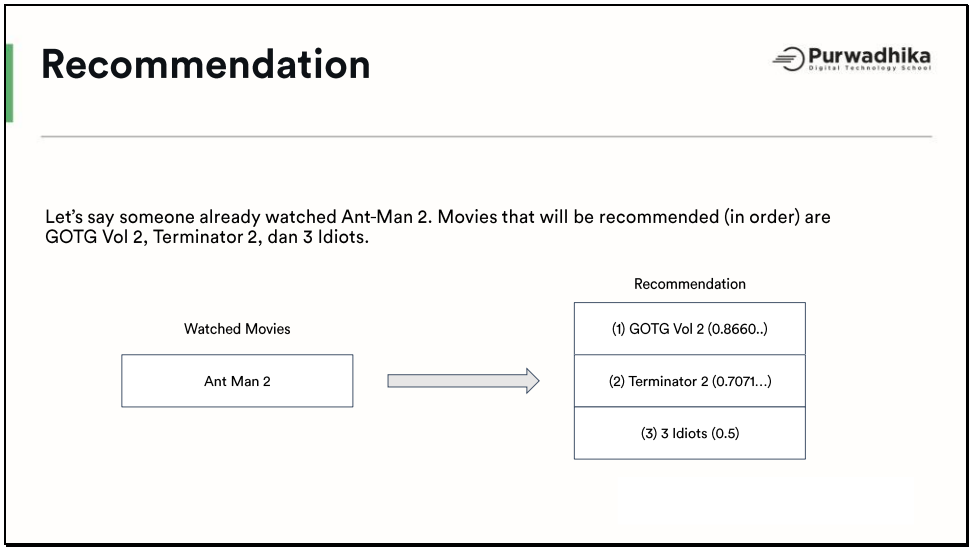


Pada kenyataannya genre yang digunakan sebagai profil tidak hanya dua, ada lebih daripada itu. Sekarang kita gunakan data yang lebih realistis, dengan daftar film yang masih sama tetapi variasi genre yang lebih banyak.

Kita akan gunakan formula sebagai berikut dimana x adalah nilai dari konten suatu item dan y adalah nilai atribut-atribut item lainnya. Nilai dari cosine similarity berkisar antara 0 hingga 1. Nilai 1 artinya dua item yang dibandingkan memiliki nilai konten yang sama persis dan nilai 0 artinya dua item yang dibandingkan jelas berbeda.

Sekarang kita coba hitung seberapa mirip Ant Man 2 dengan GOTG Vol 2. Pertama, kita kalikan masing-masing nilai dari genre kemudian dibagi dengan perkalian dari akar kuadrat masing-masing genre. Akhirnya kita peroleh nilai cosine similarity antara Ant Man 2 yaitu sebesar 0.8660. Dengan cara yang sama kita hitung nilai cosine similarity antara Ant Man 2-Terminator 2 dan Ant Man 2-3 Idiots. Setelah kita kita hitung, kita peroleh nilainya secara berturut-turut 0.7071 dan 0.5. Film yang paling mirip dengan Ant Man 2 secara berturut-turut adalah GOTG Vol 2, Terminator 2 dan 3 Idiots.

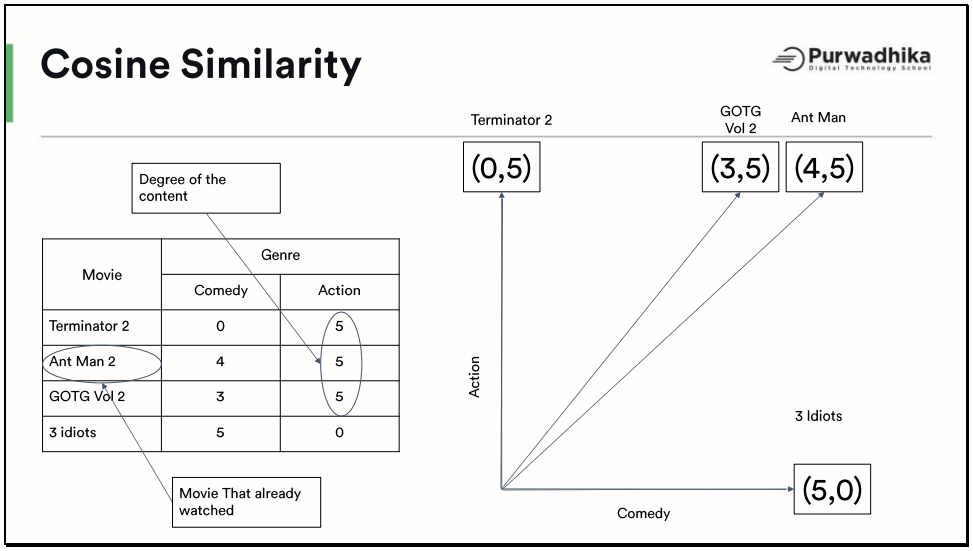
Slide 18



Seandainya seseorang menonton Ant Man 2. Film yang akan direkomendasikan dahulu secara berturut-turut adalah GOTG Vol 2, Terminator 2 dan 3 Idiots. Pada prakteknya kita dapat memberi batasan seberapa mirip items yang akan direkomendasikan. Misalkan kita membatasi bahwa film yang akan direkomendasikan perlu memiliki kemiripan di atas 0.7 maka film yang akan direkomendasikan hanya GOTG Vol 2 dan Terminator 2.

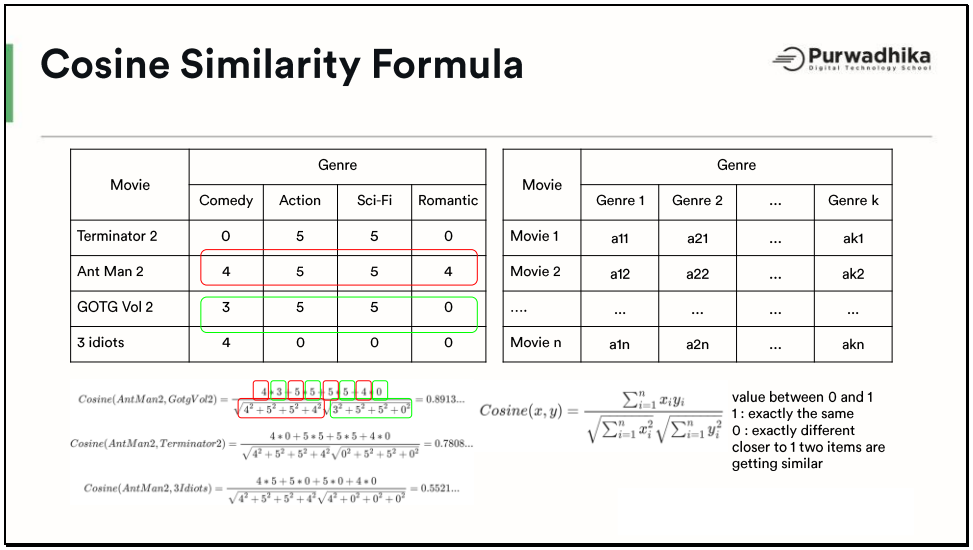
threshold

Slide 19



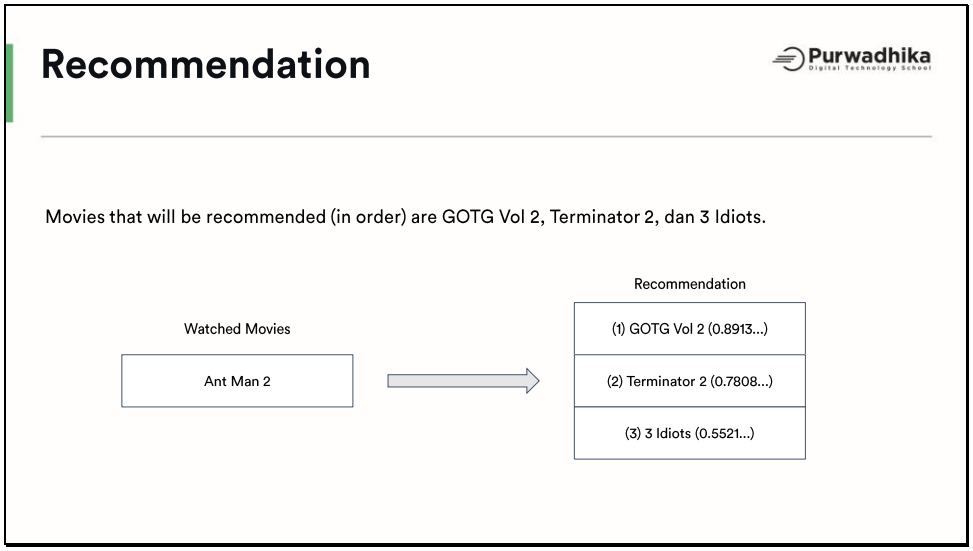
Sebelumnya nilai dari setiap konten hanya bersifat biner 0 dan 1. Tidak menutup kemungkinan kita akan mendapati data yang berbeda seperti pada contoh berikut ini. Dalam data ini kita menandai seberapa besar bobot genre dari masing-masing film.

Slide 20



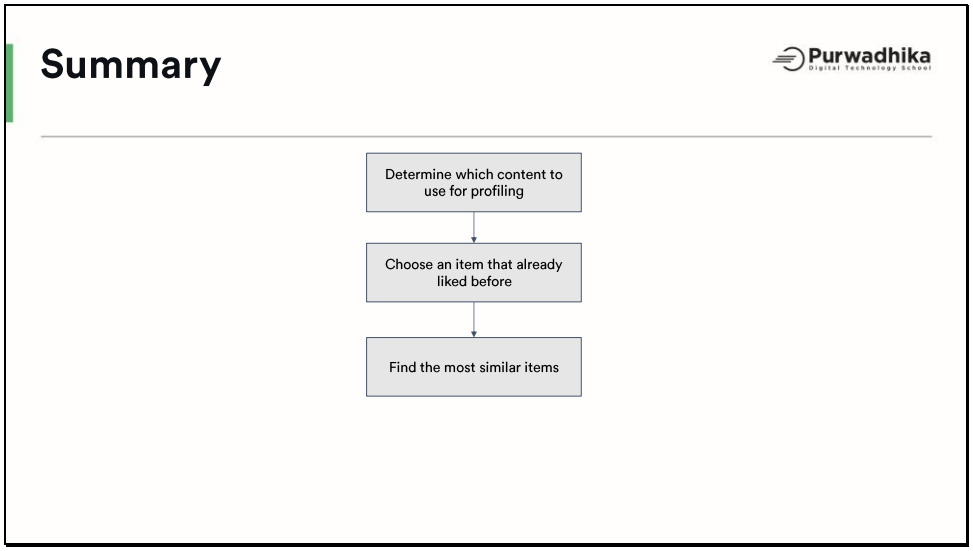
Dengan cara yang sama dengan ilustrasi sebelumnya, nilai cosine similarity film Ant Man 2 dengan film GOTG Vol 2, Terminator 2 dan 3 Idiots secara berturut-turut adalah 0.8913, 0.7808 dan 0.5521.

Slide 21



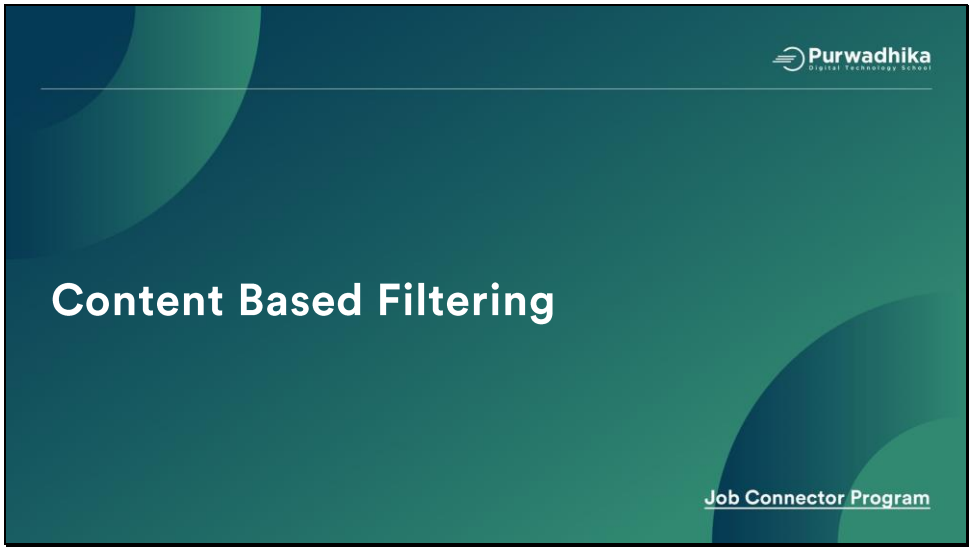
Film yang akan direkomendasikan terlebih dahulu secara berturut-turut adalah GOTG Vol2, Terminator 2 dan 3 Idiots.

Slide 22

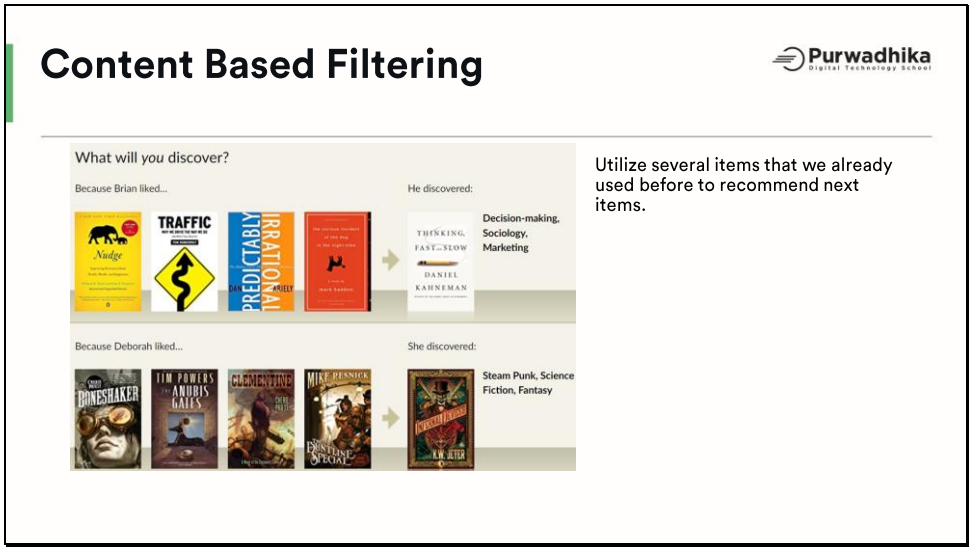


Jadi, ketika kita merangkum bagaimana content based dengan similarity measure bekerja. Prosesnya secara umum terbagi menjadi 3 bagian. Pertama, kita tentukan konten apa yang akan digunakan sebagai profil untuk setiap item. Kedua, pilih satu items yang disukai. Terakhir, temukan item-item lain yang mirip dengan item yang disukai.

Slide 23


Purwadhika
Digital Technology School
Content Based Filtering
Job Connector Program

Slide 24

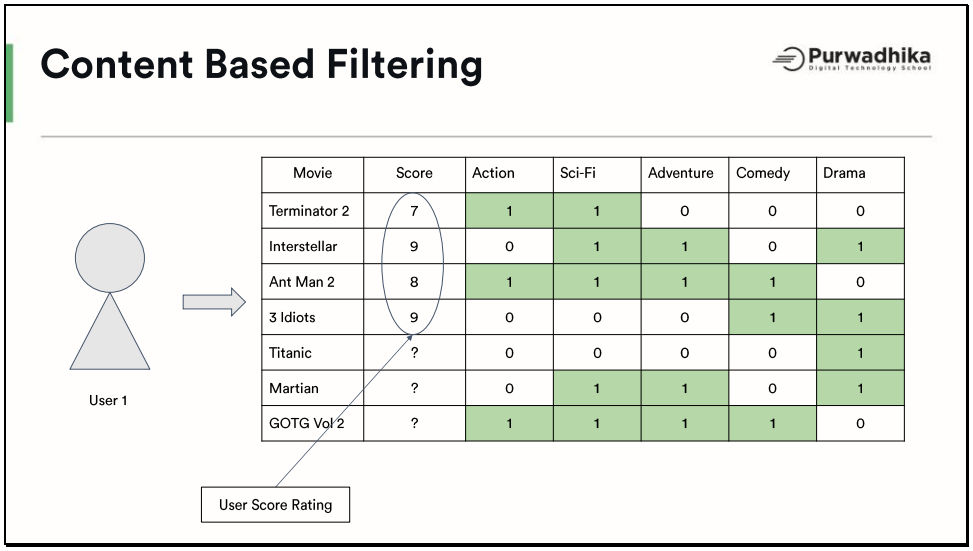


Content Based Filtering

Content based filtering memanfaatkan sejumlah items yang telah kita gunakan sebelumnya. Perhatikan bahwa pada metode sebelumnya kita hanya memanfaatkan salah satu item yang telah digunakan. Pada metode ini kita memanfaatkan beberapa item sekaligus.

Misalkan si Brian menyukai beberapa buku berikut ini. Content based filtering akan memberikan rekomendasi buku lain yang memiliki kemiripan dengan buku-buku yang telah digunakan sebelumnya. Si Brian menyukai buku yang bergenre Decision-Making, Sosiologi dan Marketing maka buku-buku yang direkomendasikan akan seperti itu juga. Begitu juga dengan si Deborah yang menyukai buku bergenre Steampunk, Science, Fiction dan Fantasy.

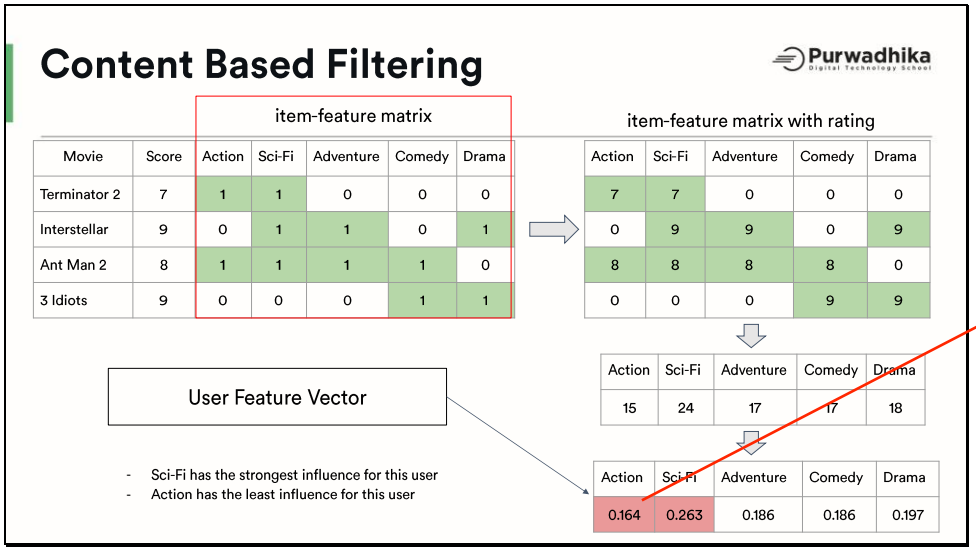
Slide 25



Movie	Score	Action	Sci-Fi	Adventure	Comedy	Drama
Terminator 2	7	1	1	0	0	0
Interstellar	9	0	1	1	0	1
Ant Man 2	8	1	1	1	1	0
3 Idiots	9	0	0	0	1	1
Titanic	?	0	0	0	0	1
Martian	?	0	1	1	0	1
GOTG Vol 2	?	1	1	1	1	0

Sekarang akan kita lihat bagaimana content based filtering bekerja untuk satu user. Sebut saja user 1, user tersebut telah memberikan rating kepada sejumlah film dan ada sejumlah film yang belum ditonton sebelumnya. Kita ingin mengetahui film apa yang ingin dia tonton selanjutnya.

Slide 26

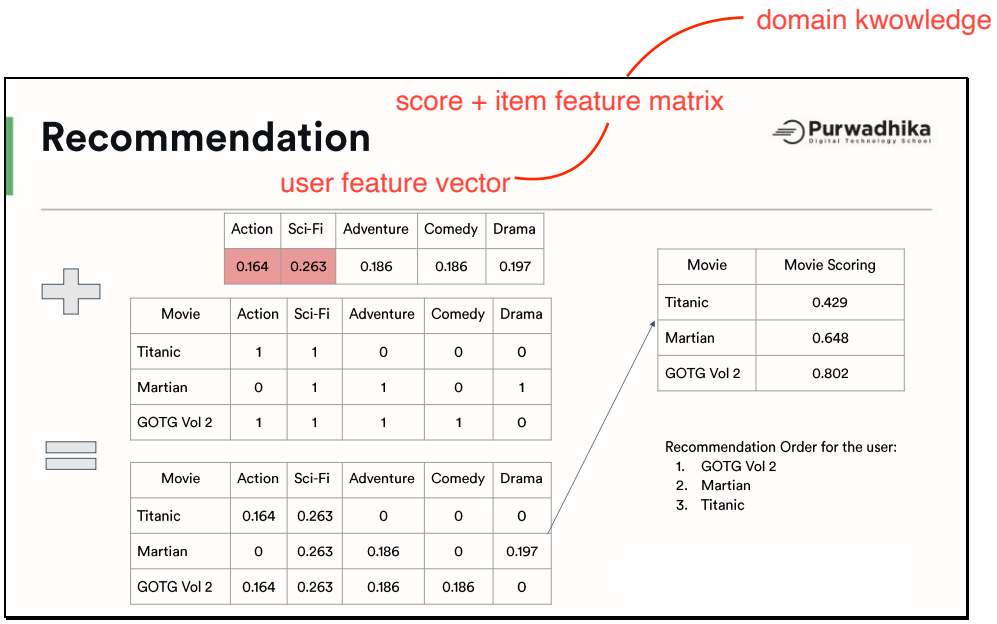


Mula-mula kita buat item-feature matrix. Matrix ini merupakan kombinasi antara rating yang diberikan untuk item dan genre.

Matrix tersebut kita rangkum sehingga kita peroleh preferensi user 1 secara keseluruhan. Preferensi yang kita gunakan untuk kasus ini adalah preferensi terhadap genre. Untuk memperoleh preferensi user terhadap genre kita jumlahkan rating yang diberikan oleh user untuk setiap genre. Setelah itu kita buat preferensinya dalam bentuk persentase atau proporsi. Preferensi user terhadap konten yang digunakan dinamakan dengan User Feature Vector.

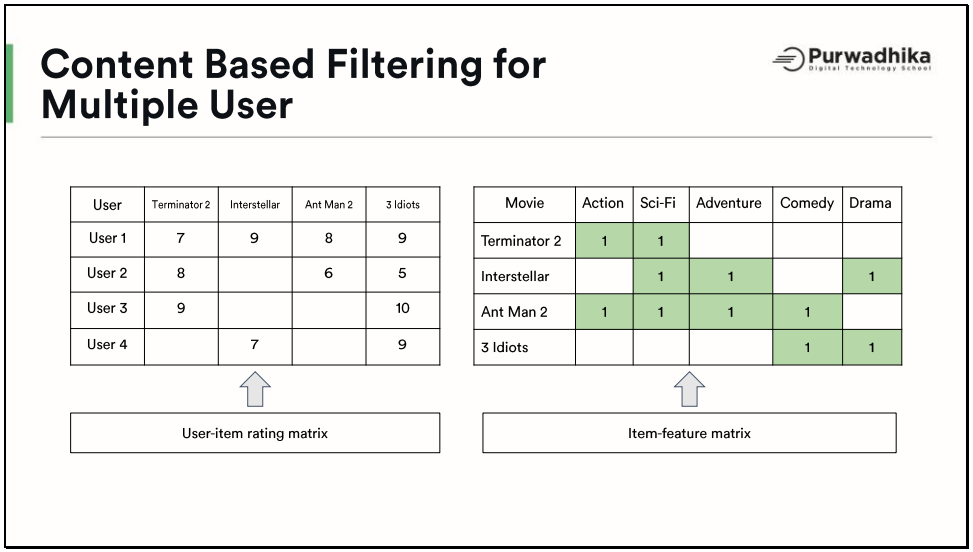
User feature vector yang telah diperoleh akan digunakan untuk mengukur minat terhadap item lain yang belum digunakan. Selanjutnya kita akan mengukur minat user 1 terhadap sejumlah film yakni Titanic, Martian dan GOTG Vol 2.

Slide 27



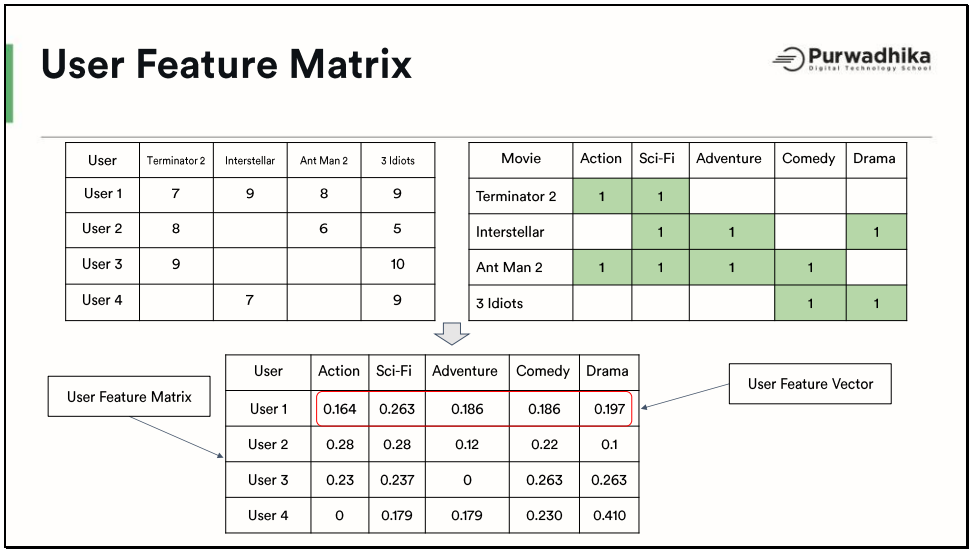
Kita kombinasikan user feature vector dengan item-feature matrix. Lalu kita hitung total skor untuk masing-masing item dengan melakukan penjumlah skor dari masing-masing genre. Kita peroleh skornya ternyata film dengan skor terbesar secara berturut-turut adalah GOTG Vol 2, Martian dan Titanic.

Slide 28



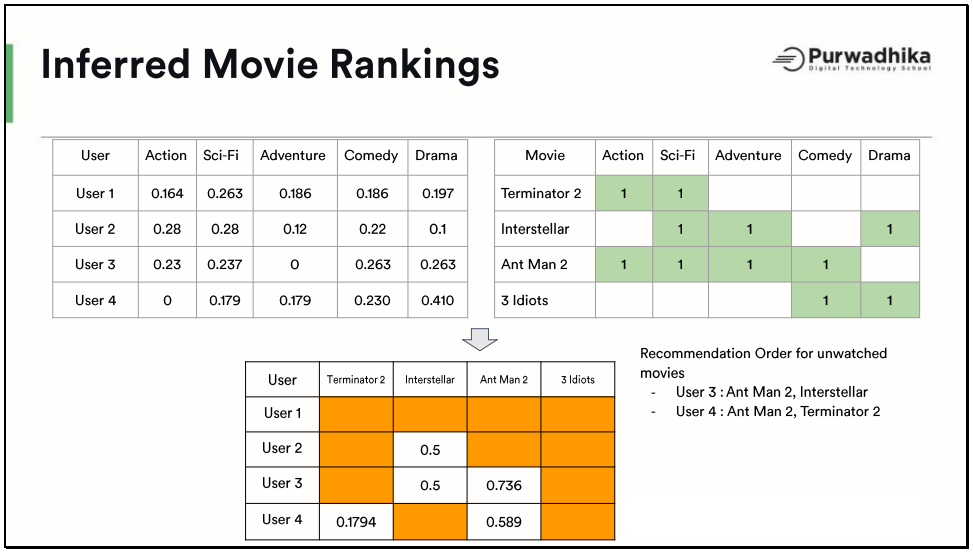
Dalam prakteknya, kita perlu melakukan rekomendasi untuk banyak pengguna tidak hanya satu. Yang kita perlukan ada dua hal yaitu, user-item rating matrix dan item-feature matrix.

Slide 29



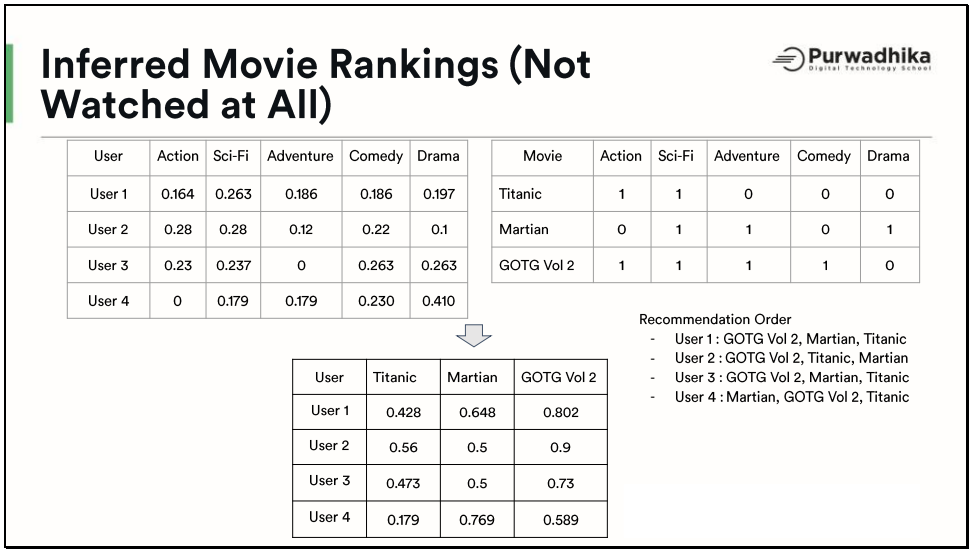
Pada dasarnya kita lakukan hal yang sama yaitu menghitung user feature vector tapi kali ini kita hitung untuk setiap user yang ada. User feature vector kita kumpulkan lalu membentuk user feature matrix.

Slide 30



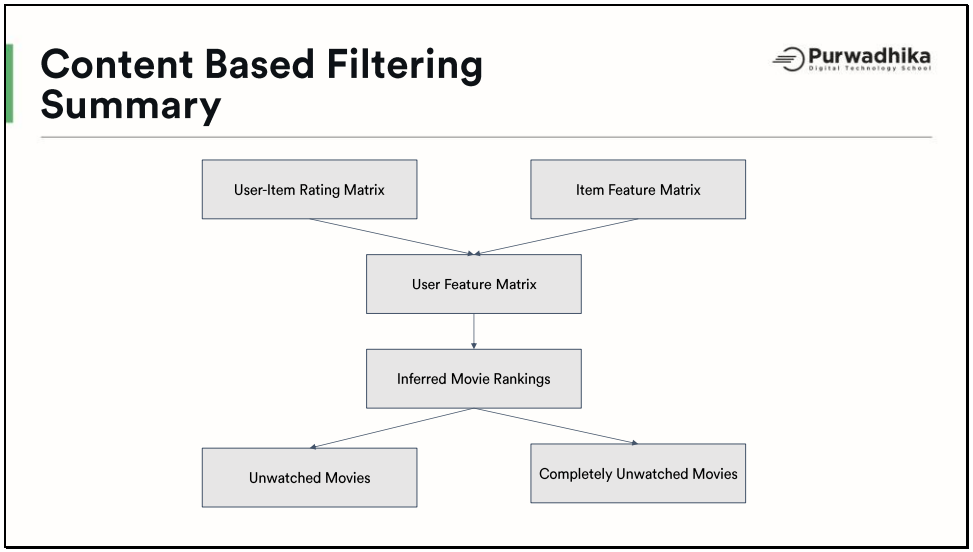
Selanjutnya, user feature matrix kita kombinasikan dengan item feature matrix agar kita dapat memperoleh skor dari film yang belum ditonton oleh setiap user. Kita dapat melihat bahwa dari sejumlah film yang belum dilihat oleh user 3 dan user 4 ternyata film yang paling direkomendasikan untuk ditonton selanjutnya adalah Ant Man 2.

Slide 31



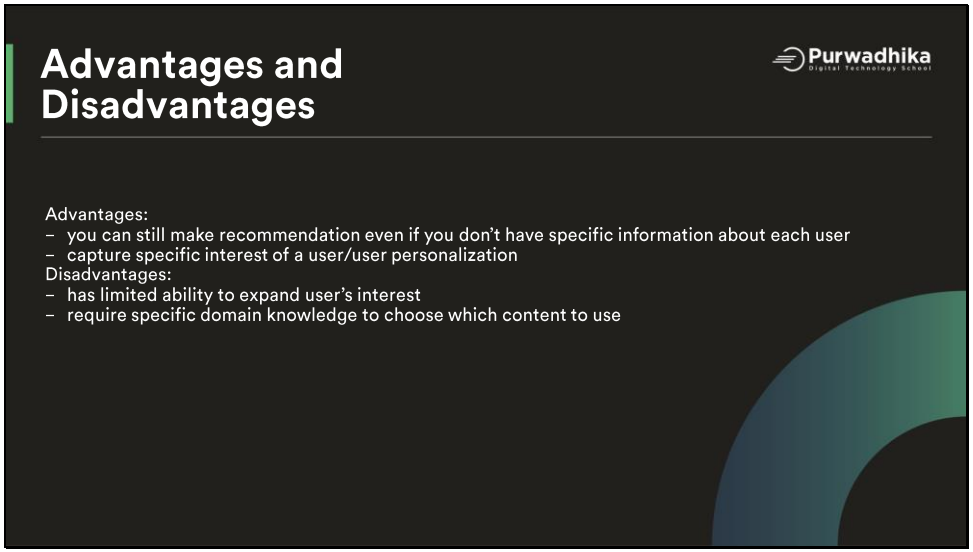
Kita juga dapat melakukan rekomendasi terhadap film-film yang belum ditonton oleh user mana pun. Kita hendak memberikan rekomendasi film GOTG Vol 2, Titanic dan Martian. Ternyata user 1, user 2 dan user 3 sama-sama paling pertama diberikan rekomendasi GOTG Vol 2 walaupun ada perbedaan untuk urutan kedua dan ketiganya. User 4 paling pertama diberi rekomendasi film Martian.

Slide 32



Jadi, berdasarkan uraian-uraian dari ilustrasi sebelumnya. Content based filtering berawal dari user-item rating matrix dan item-feature matrix. Kemudian, kita kombinasikan kedua matrix tersebut menjadi user feature matrix yang menyatakan preferensi setiap user terhadap konten items yang digunakan. Lalu kita dapat menghitung skor seberapa minat user terhadap film yang belum ditonton, baik film yang sudah ditonton oleh user lain atau film yang belum ditonton sama sekali oleh user lainnya.

Slide 33

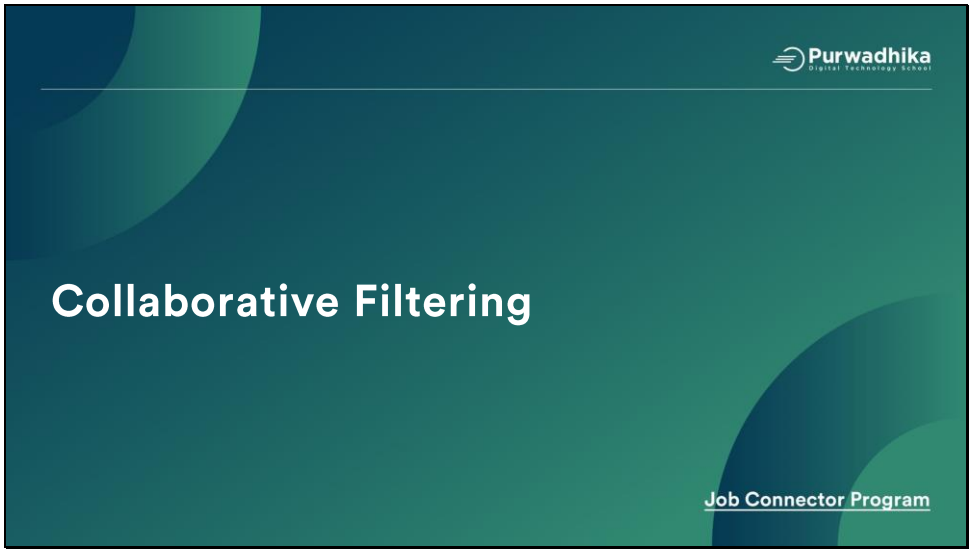


Advantages and Disadvantages

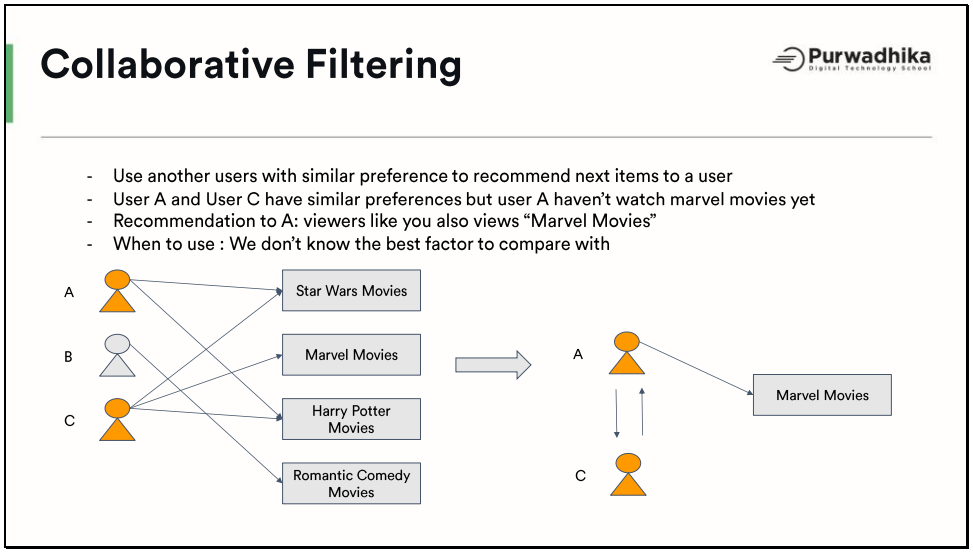
Content based recommendation system tentu memiliki keunggulan dan kelebihan. Keunggulan dari metode ini adalah kita tetap dapat membangun recommendation system walaupun kita tidak memiliki informasi spesifik untuk masing-masing user. Metode ini juga dapat menangkap ketertarikan yang sifatnya spesifik dari setiap user.

Kekurangannya, metode ini memiliki keterbatasan dalam mengembangkan minat pengguna. Kekurangan lainnya, metode ini memerlukan domain knowledge yang spesifik untuk menentukan konten yang paling tepat untuk digunakan.

Slide 34


Purwadhika
Digital Technology School
Collaborative Filtering
Job Connector Program

Slide 35

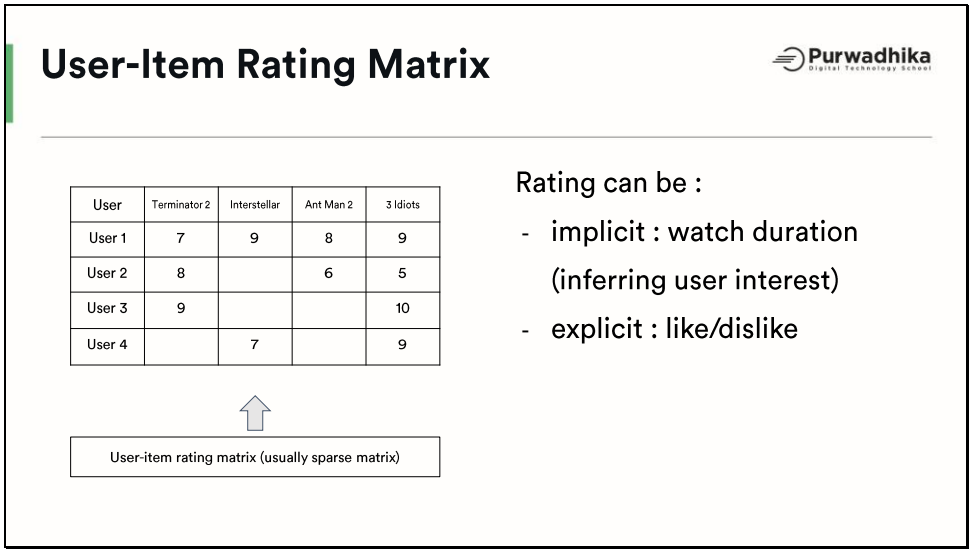


COLLABORATIVE FILTERING

Collaborative filtering memanfaatkan user lain yang preferensi mirip dalam memberikan rekomendasi. Misalkan, kita memiliki sejumlah user yaitu, user A, user B dan user C, serta user lainnya. Ternyata user A memiliki kemiripan preferensi dengan user C. Mereka sama-sama menyukai film-film star wars dan film-film Harry Potter tetapi user A belum pernah sama sekali menonton film-film marvel. Dengan collaborative filtering, user A akan mendapatkan rekomendasi film-film marvel karena user lain (user C) yang preferensinya mirip menonton film-film marvel. Seakan-akan user A menanyakan kepada user C tentang film apa yang ia hendak tonton selanjutnya berhubung mereka memiliki kemiripan preferensi.

Seperti yang sudah dijelaskan sebelumnya content based recommendation system memerlukan domain knowledge yang spesifik untuk menentukan konten mana yang akan digunakan. Dengan collaborative filtering kita tetap dapat membangun recommendation system walaupun kita tidak tahu konten apa yang mau kita gunakan.

Slide 36



Dalam collaborative filtering, yang kita perlukan adalah user-item rating matrix. Matrix ini berisi data setiap user beserta rating yang diberikan terhadap item yang telah digunakan. Biasanya matrix ini banyak yang nilainya kosong. Matrix yang memiliki banyak nilai kosong biasanya disebut dengan sparse matrix. Rating dapat bersifat implisit seperti durasi menonton suatu video. Rating ini kita ketahui nilainya secara tidak langsung. Ada juga rating yang sifatnya langsung seperti feedback berupa like atau dislike. Jadi, kita mengetahui bagaimana ketertarikan user secara langsung.

Slide 37

How To Measure User's Preferences ?

Purwadhika Digital Technology School

Implicit data collection examples:

- Observing the items that a user views in an online store
- Analyzing item/user viewing times
- Keeping a record of the items that a user purchases online



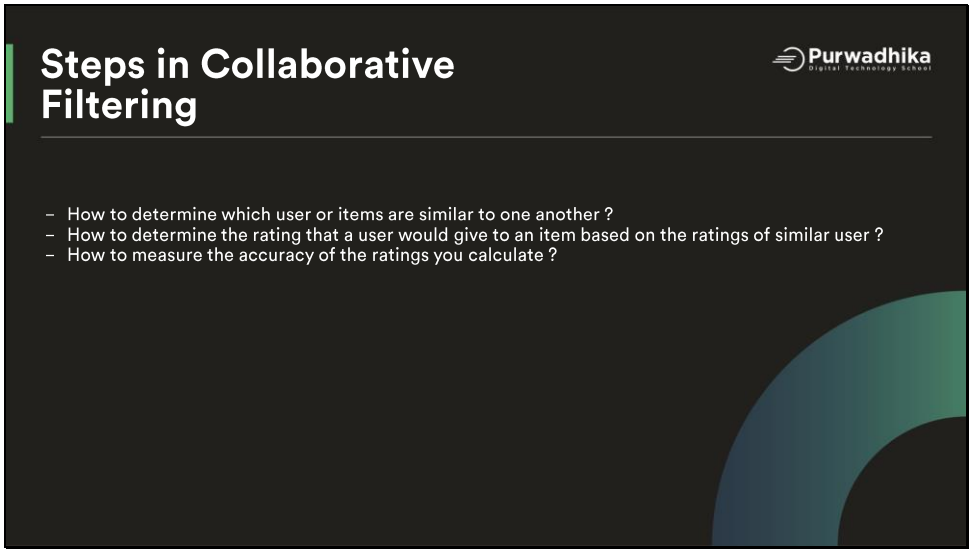
Explicit data collection examples:

- asking a user to rate
- asking a user to rank a collection of items from most favorite to least favorite

Contoh-contoh lain dari rating yang sifatnya implisit yang mungkin anda sering perhatikan di antaranya adalah ilustrasi-ilustrasi berikut ini. Suatu online store mengamati item-item apa saja yang dilihat oleh user. Analisa rating juga dapat dilakukan berdasarkan berapa kali user melihat suatu item tertentu atau dapat juga dilakukan berdasarkan berapa kali suatu item dilihat oleh user.

Lalu bagaimana dengan rating yang sifatnya eksplisit. Kita dapat peroleh dengan cara menanyakan secara langsung terhadap user. Selain itu, rating eksplisit juga dapat diperoleh dengan cara meminta user untuk mengurutkan koleksi item yang mereka punya dari yang paling favorit.

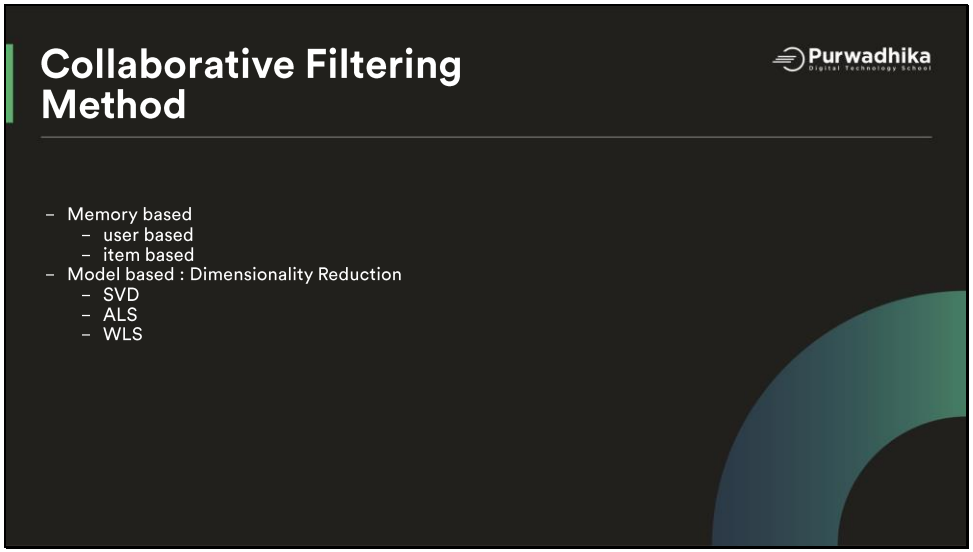
Slide 38



Steps in Collaborative Filtering

Secara garis besar, collaborative filtering akan kita bedakan menjadi tiga tahap. Pertama metode apa yang akan kita gunakan untuk mengukur seberapa mirip preferensi antara satu user dengan user lainnya. Kedua, bagaimana kita memprediksi rating yang akan user berikan kepada item yang belum mereka gunakan. Ketiga, mengukur seberapa baik hasil prediksi rating yang akan kita gunakan.

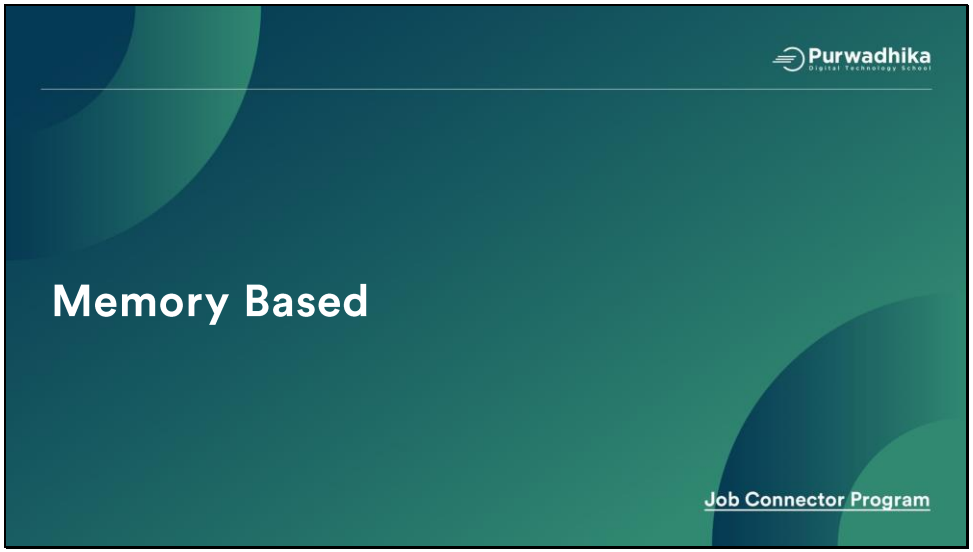
Slide 39



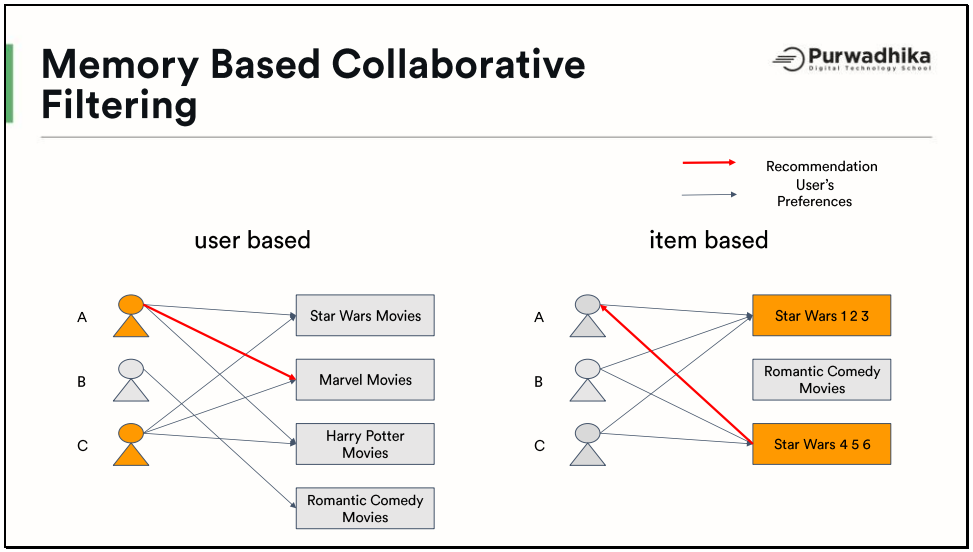
Collaborative Filtering Method

Collaborative filtering method terbagi menjadi dua jenis yaitu memory based dan model based. Kita akan membahas satu per satu metode apa yang dapat digunakan dalam kedua jenis metode tersebut. Yang akan kita bahas dalam memory based adalah user based dan item based. Sedangkan, yang akan kita bahas dalam model based adalah seputar dimensionality reduction seperti Singular Value Decomposition (SVD), Alternating Least Square (ALS) dan Weighted Alternating Least Square (WALS).

Slide 40


Purwadhika
Digital Technology School
Memory Based
Job Connector Program

Slide 41



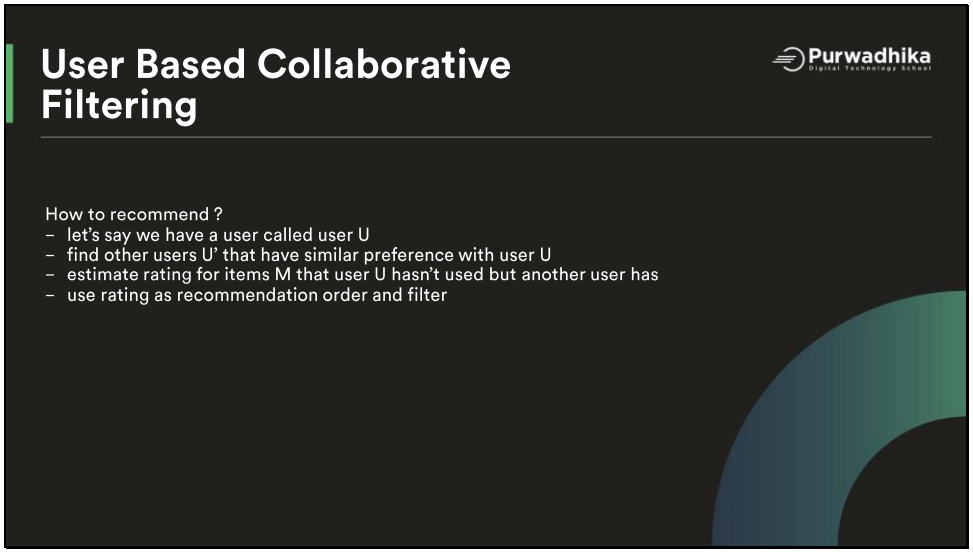
Memory Based Collaborative Filtering Method

Seperti yang sudah dijelaskan sebelumnya, memory based filtering terbagi menjadi dua, yaitu user-based dan item-based.

Dengan user-based ibaratnya kita mengumpulkan user yang mirip preferensinya kemudian menanyakan kepada mereka tentang item apa yang akan kita sukai.

Pada item-based kita kumpulkan item-item yang penggunanya serupa. Lalu pengguna-pengguna tersebut akan saling merekomendasikan

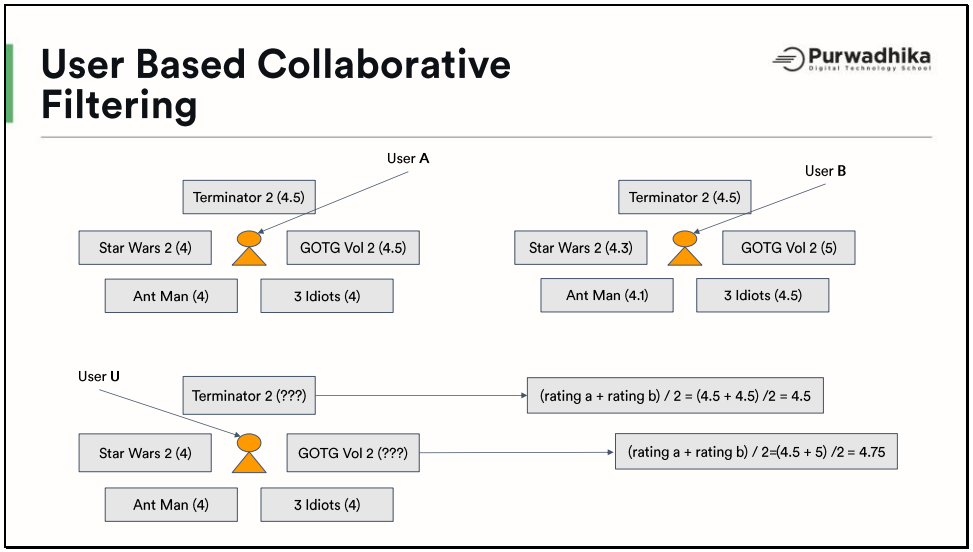
Slide 42



User-based

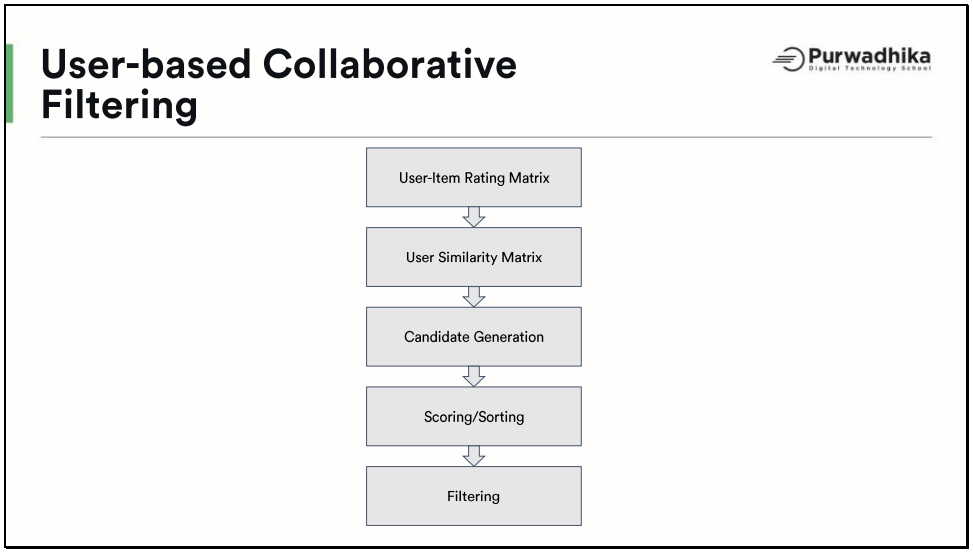
Kita akan melihat lebih detail bagaimana user-based recommendation bekerja. Pertama katakanlah kita memiliki seorang user U. Lalu, kita cari user-user lain yang preferensinya mirip dengan si U sebut saja kumpulan user U'(user A, B, C dan seterusnya). kumpulan user U' ternyata sudah menggunakan sejumlah item yang U belum gunakan sama sekali, sebut saja item-item tersebut kumpulan item M (item 1 item 2 itm 2 dst). Kita dapat melakukan estimasi terhadap rating yang akan U beri terhadap kumpulan item M berdasarkan rating dari user U' yang sudah menggunakannya. Kita urutkan hasil estimasi ratingnya untuk item-item M atau bisa juga kita filter sekian item terbaik.

Slide 43



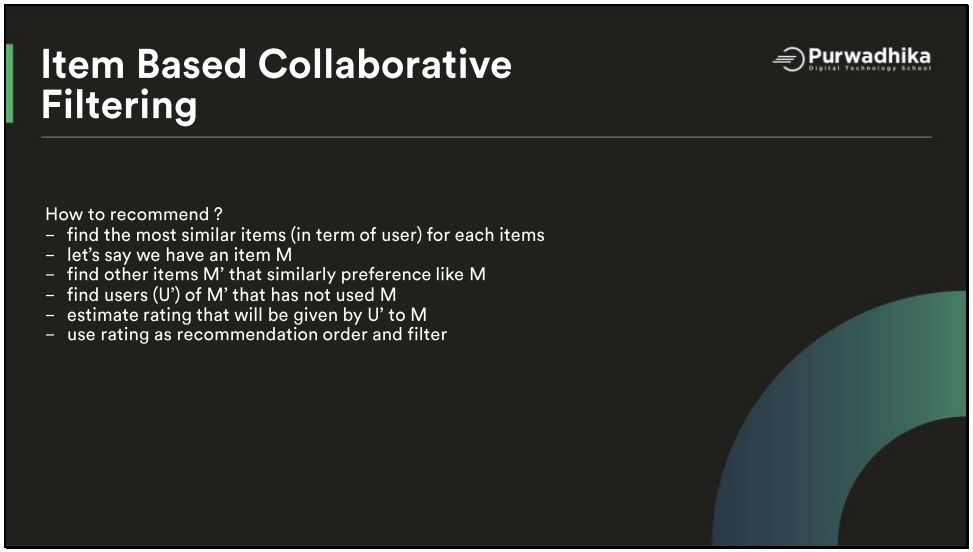
Contohnya kita punya user U, ia telah menonton kumpulan film Star Wars 2, Ant Man 2 dan 3 Idiots. User A dan user B sudah menonton ketiga film tersebut tapi ada tontonan mereka yang belum user U lihat yaitu, Terminator 2 dan GOTG Vol 2. Kita dapat memprediksi berapa rating yang akan diberikan U terhadap Terminator 2 dan GOTG Vol 2 berdasarkan rating dari user A dan user B. Kita dapat mengestimasi rating suatu film menggunakan rata-rata rating dari user lainnya. User U diperkirakan akan memberikan rating terhadap Terminator 2 sebesar 4.5. Nilai tersebut diperoleh dari rata-rata rating user A dan rating user B terhadap film terminator. Dengan cara yang sama, kita dapat mengestimasi rating yang akan diberikan user U terhadap film GOTG Vol 2.

Slide 44



Jika kita ringkas bagaimana user-based bekerja maka semuanya akan dimulai dari user-item rating matrix. Kita perlu siapkan data item siapa yang menggunakan dan berapa ratingnya. Kemudian, kita buat user similarity matrix untuk mengetahui siapa saja yang preferensi serupa. Lalu, kita tentukan siapa saja yang akan kita berikan rekomendasi dan estimasi rating untuk item-item yang belum mereka gunakan. Selanjutnya, kita pilih dan membuat prioritas rekomendasi untuk setiap user.

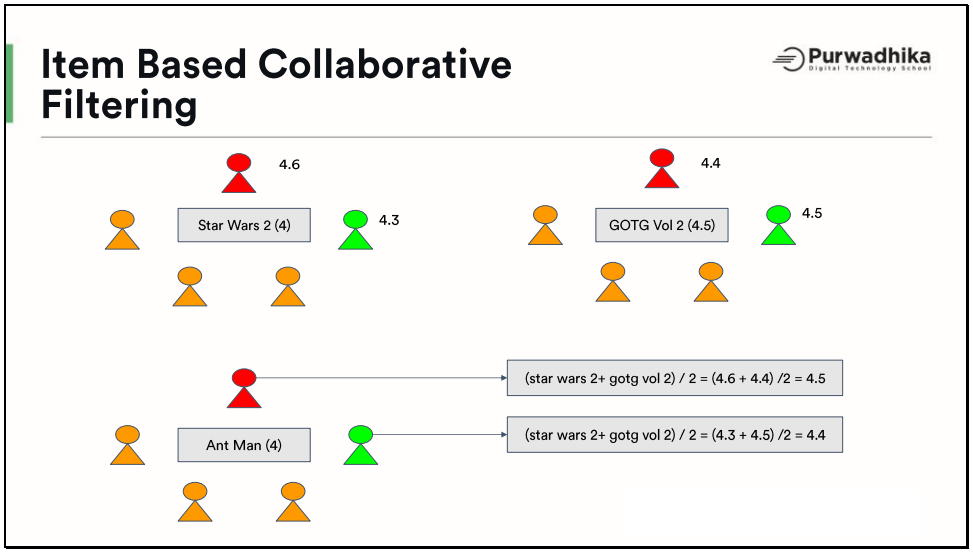
Slide 45



Item-based

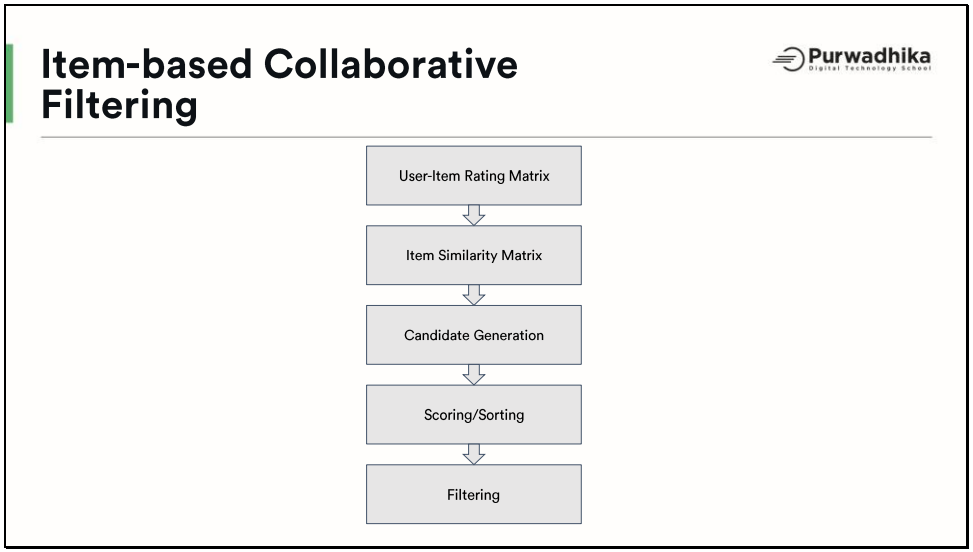
Sedangkan untuk item-based collaborative filtering kita tentukan item-item yang serupa untuk setiap item dalam hal siapa penggunanya. Katakan lah kita punya suatu item yang kita sebut dengan M. Kita cari item-item lain yang mirip penggunanya, sebut saja item-item tersebut dengan kumpulan item M' (item 1 item 2 dst). Temukan user-user yang telah menggunakan kumpulan item M' tapi belum menggunakan M. Estimasi rating yang akan diberikan oleh U' kepada M. Terakhir, kita gunakan hasil estimasi rating sebagai ukuran untuk prioritas rekomendasi.

Slide 46



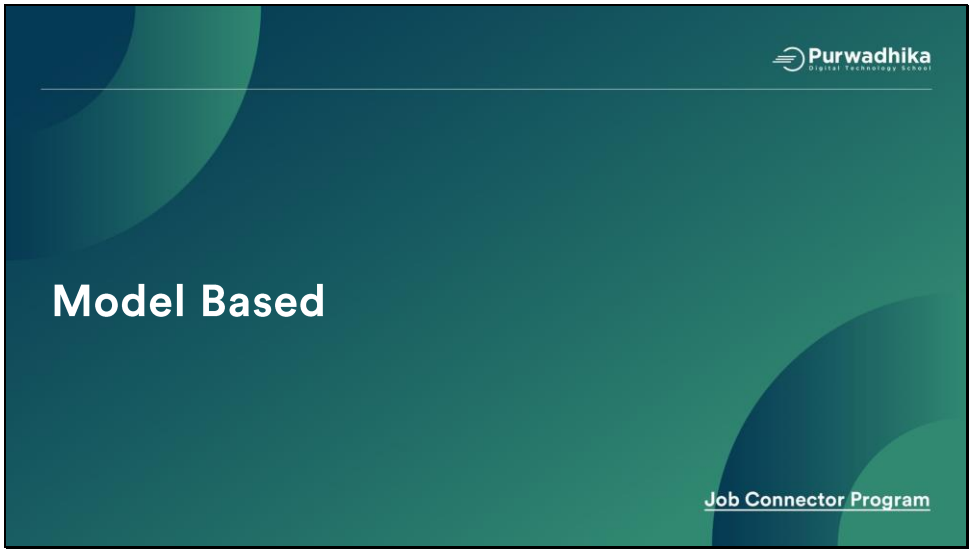
Misalkan kita punya film yang akan kita rekomendasikan yaitu Ant Man 2. Lalu, Kita cari film-film yang mirip dengan Ant Man 2 dalam hal siapa yang menggunakannya. Film-film tersebut adalah Star Wars 2 dan GOTG Vol 2. Sekarang kita punya sekumpulan user dan kita mendapati bahwa Ant Man 2 belum ditonton oleh user hijau dan user merah. Kita dapat mengestimasi berapa rating user merah untuk film Ant Man 2 berdasarkan rata-rata rating user tersebut untuk film Star Wars 2 dan GOTG Vol 2. Dengan cara yang sama kita dapat estimasi rating yang akan diberikan oleh user hijau terhadap Ant Man 2.

Slide 47

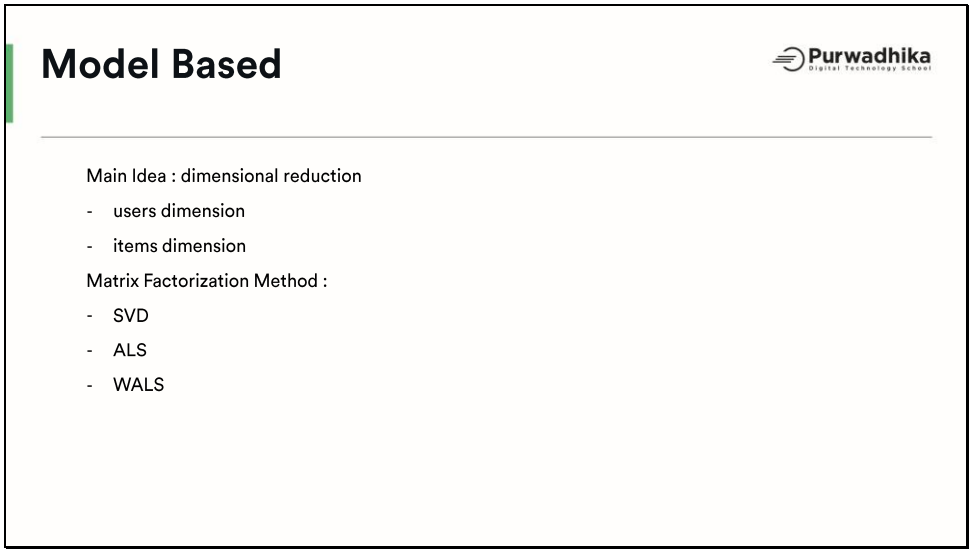


Jika kita ringkas bagaimana item-based bekerja, semuanya berawal dari user-item rating matrix. Kita perlu siapkan data item, siapa yang menggunakan serta berapa ratingnya. Kemudian, kita buat item similarity matrix untuk mengetahui kemiripan setiap item terhadap item-item lainnya. Setelah itu, kita tentukan siapa saja yang akan kita berikan rekomendasi dan estimasi rating untuk item-item yang belum mereka gunakan. Terakhir, kita pilih dan membuat prioritas rekomendasi untuk setiap user.

Slide 48


Purwadhika
Digital Technology School
Model Based
Job Connector Program

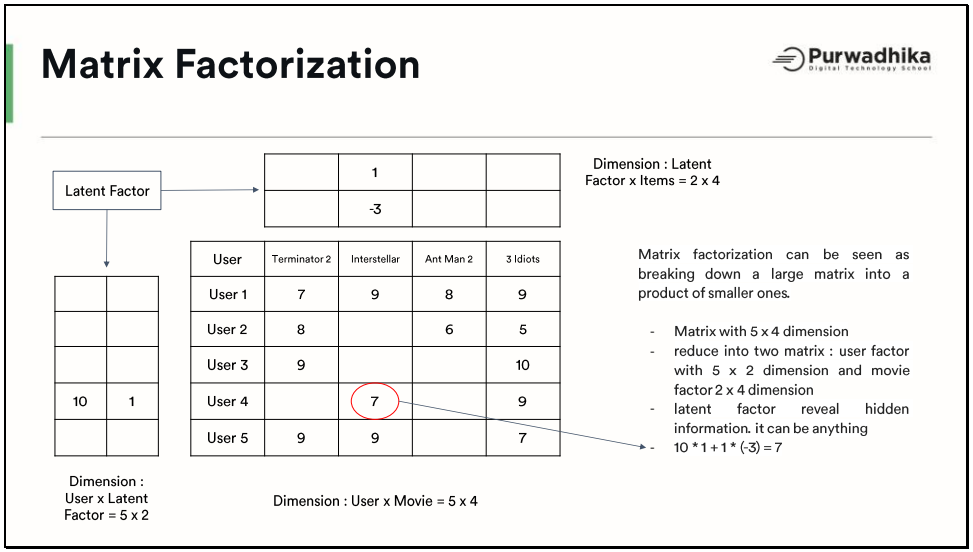
Slide 49



Model Based Collaborative Filtering

Metode yang akan kita bahas selanjutnya adalah model based collaborative filtering. Ide utama dari metode ini adalah dimensional reduction. Metode yang akan kita gunakan untuk model based collaborative filtering adalah matrix factorization. Ada beberapa opsi matrix factorization yang dapat digunakan dalam collaborative filtering yaitu Singular Value Decomposition (SVD), Alternating Least Square (ALS) dan Weighted Alternating Least Square (WALS).

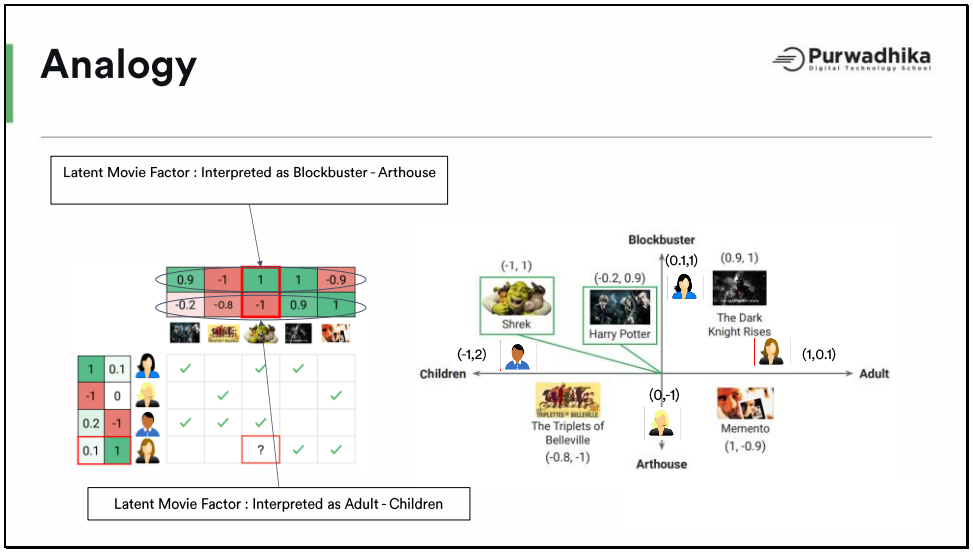
Slide 50



Matrix factorization dapat dilihat sebagai suatu metode untuk memecah matrix yang besar menjadi dua matrix yang lebih kecil. Pada contoh berikut mula-mula kita punya matrix yang berdimensi 5 x 4. Kita pecah matrix ini menjadi dua matrix yang lebih kecil. Matrix pertama berukuran 5 x 2. Matrix tersebut mencirikan karakteristik tersembunyi dalam user. Matriks kedua yaitu matrix items yang berukuran 2 x 4. Matrix ini mencirikan karakteristik tersembunyi yang ada dalam film.

Kita memprediksi berapa rating user terhadap item tertentu dengan cara berikut. Nilai latent factor pertama user 4 (10) dikalikan dengan nilai latent factor pertama film interstellar (1) ditambah dengan Nilai latent factor kedua user 4 (1) dikalikan dengan nilai latent factor kedua film interstellar (-3). Hasil prediksi ratingnya adalah 7. Begitulah cara untuk mengestimasi rating user terhadap suatu item.

Slide 51



Sekarang kita akan analogikan bagaimana matrix factorization bekerja. Mula-mula kita punya user-item rating matrix sebagai berikut. Lalu, kita reduksi matrix tersebut menjadi user matrix dan item matrix. Kemudian kita buat plot untuk setiap film terlebih dahulu.

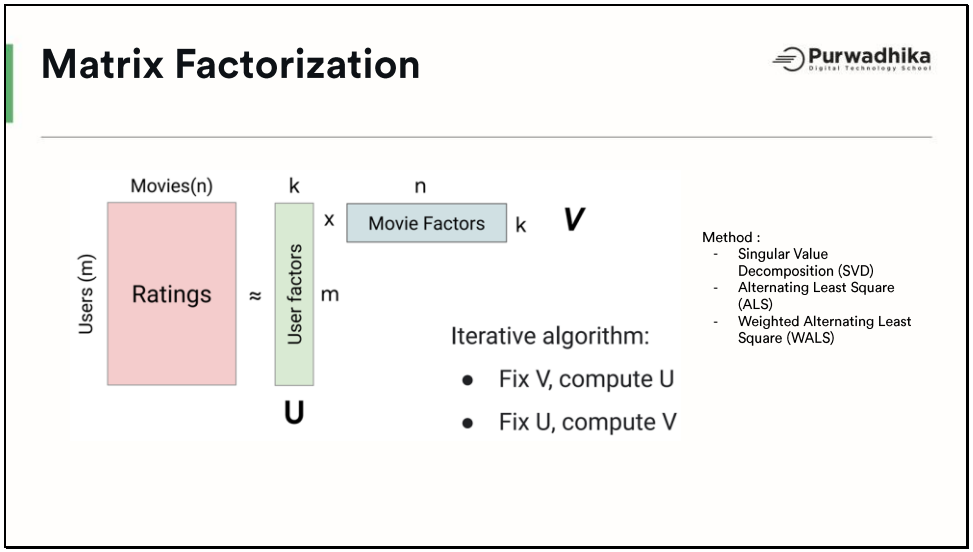
Latent factor pertama ada pada sumbu y dan latent factor kedua ada pada sumbu x. Kita perhatikan bahwa hasil plotting membentuk pola tertentu. Semakin ke kanan posisi film, semakin film tersebut termasuk ke dalam film untuk orang dewasa. Sedangkan, semakin ke kiri suatu film, semakin film tersebut ke dalam film untuk anak-anak.

Sekarang kita lihat dari sumbu Y, tingginya posisis suatu film mencirikan bahwa film tersebut termasuk ke dalam film-film blockbuster sedangkan semakin ke bawah sebaliknya.

Latent factor yang digunakan hanya anggapan semata, bukan karakteristik yang sesungguhnya. Pada dasarnya kita tidak mengetahui apakah latent factor untuk item benar-benar mencirikan film untuk dewasa atau anak-anak dan film blockbuster atau arthouse.

Sebelumnya kita menganalisa dari sisi film (item). Jika kita lakukan hal yang sama terhadap user. Kita bisa saja melakukan hal yang serupa yakni memberikan latent factor terhadap user. Yang kita lakukan di sini hanya menempatkan user sesuai dengan nilai dari latent factornya. Kita dapat melihat bagaimana preferensi user berdasarkan posisinya terhadap suatu film (item).

Slide 52



Secara metodologi, proses reduksi dimensi dalam matrix factorization serupa dengan PCA. Perbedaannya dalam PCA kita hanya melakukan reduksi sekali yaitu terhadap kolom. Dalam matrix factorization kita melakukan reduksi dua kali, yang pertama reduksi kolom dan yang kedua reduksi baris. Metode matrix factorization yang dapat digunakan diantaranya Singular Value Decomposition (SVD), Alternating Least Square (ALS) dan Weighted Alternating Least Square (WALS).

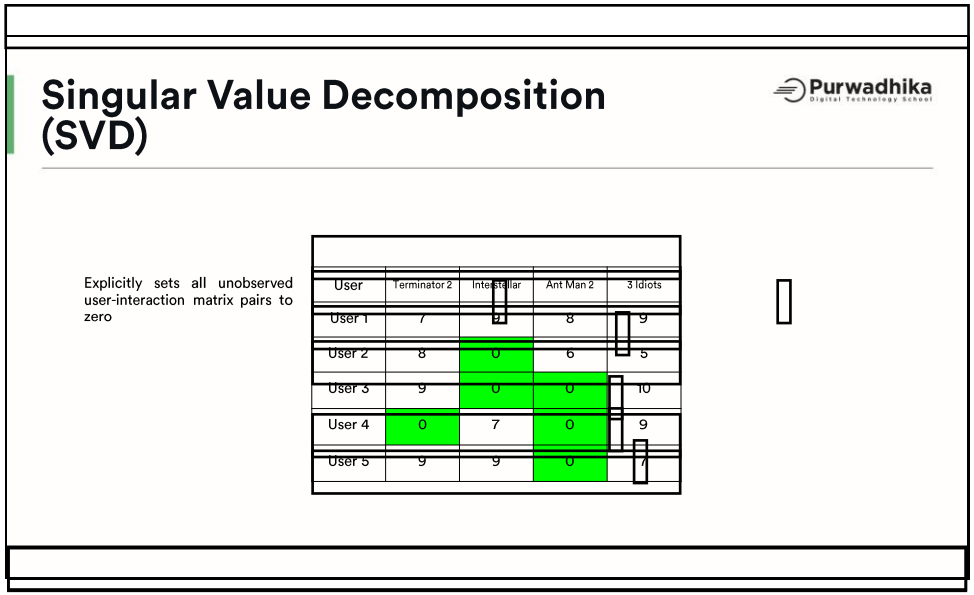
'n_epochs': [5, 10, 20],
'lr_all': [0.002, 0.005],
'reg_all': [0.02, 0.4, 0.6]}

Slide 53

- n_epochs: berapa kali iterasi, makin banyak makin baik, tapi lama
- lr_all: learning rate, tingkat perubahan (sejauh mana) perubahan parameter pd stiap iterasi
- reg_all: regulasi, semakin besar regulasi maka semakin besar penalty utk parameter (parameter tidak terlalu eskrim) -> terhindar dari overfitting

Keuntungan:
- Memanfaatkan semua data, termasuk data yang belum terisi, dalam proses pelatihan.
- Memodelkan matriks rating secara global dan menyediakan solusi yang optimal dalam bentuk matriks faktor tersembunyi.

Kerugian:
- Lebih memakan waktu dan sumber daya komputasi, terutama ketika matriks rating sangat besar.
- Rentan terhadap overfitting jika data yang tersedia terbatas.



Dengan SVD kita melakukan reduksi dimensi dengan menganggap semua data yang belum terisi dengan nilai nol.

'n_epochs': 5, -> default 20
'reg_u': 12, -> default 0.02
‘reg_i': 5 -> default 0.02

Slide 54

- n_epochs: berapa kali iterasi, makin banyak makin baik, tapi lama
- reg_u: regulasi pada user matrix
- reg_i: regulasi pada item matrix

Keuntungan:
- Lebih efisien untuk matriks rating yang sangat besar karena hanya memerlukan data yang diisi (rating yang diketahui).
- Mampu menangani data yang lebih jarang tanpa overfitting yang signifikan.

Kerugian:
- Tidak memanfaatkan data yang belum terisi, yang dapat menyebabkan ketidakakuratan dalam prediksi untuk item yang jarang diberi peringkat.
- Tidak memberikan representasi global untuk seluruh matriks rating.

Alternating Least Square (ALS)

Purwadhika Digital Technology School

Simply ignores all unobserved user-interaction matrix pairs.

User	Terminator 2	Interstellar	Ant Man 2	3 Idiots
User 1	7	9	8	9
User 2	8		6	5
User 3	9			10
User 4		7		9
User 5	9	9		7

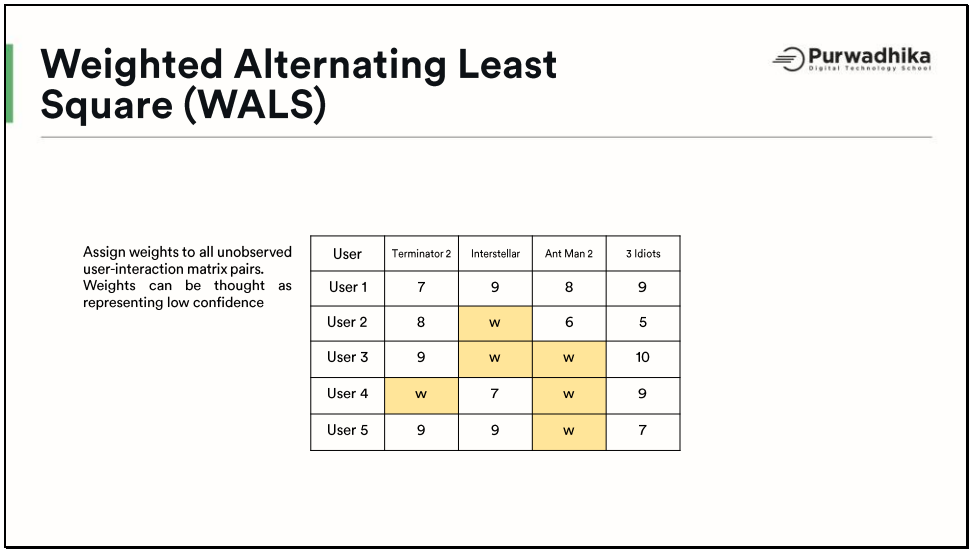
penalty besar diberikan pada user atau item yang lebih banyak isinya

jika user banyak tidak mengisi rating, maka penalty pada item lebih tinggi

ALS mengabaikan data yang tidak terisi.

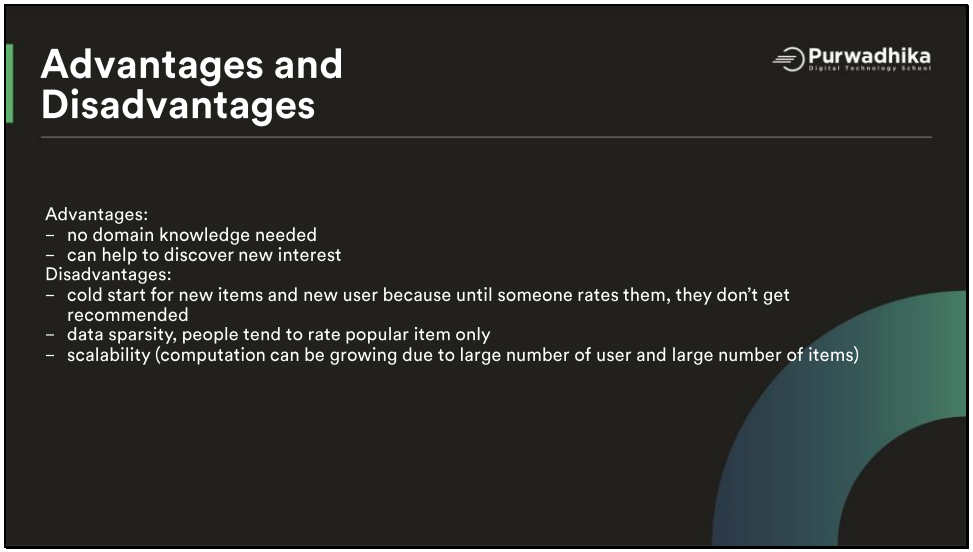
Text

Slide 55



Weighted ALS seperti SVD yakni menganggap data yang belum terisi dengan nilai nol tetapi data tersebut dibuat tidak sepenting data lainnya. Dengan kata lain bobotnya kecil.

Slide 56



Advantages and Disadvantages

Sekarang kita bahas apa keunggulan dan kekurangan dari collaborative filtering. Keunggulan dari collaborative filtering adalah pertama kita tidak memerlukan domain knowledge khusus dalam membangung recommendation system. Kedua, collaborative filtering dapat membantu pengguna untuk mencoba hal baru.

Kekurangan dari metode ini adalah kita akan menemui kesulitan ketika hendak merekomendasikan item-item baru yang belum ada ratingnya dan kita juga akan mengalami kesulitan ketika ada user-user baru yang belum pernah memberikan rating. Item baru dapat direkomendasikan setelah ada yang memberikan rating begitu juga dengan user. Kita juga akan menemui kendala dengan data sparsity. Ada sejumlah item yang kurang populer sehingga metode Collaborative filtering tidak akan mampu mendeteksi item-item tersebut dengan baik. Item-item yang direkomendasikan hanya item-item populer. Volume data yang besar juga dapat menjadi kendala ketika kita hendak menggunakan collaborative filtering karena akan terlalu makan banyak waktu dalam proses model training.

Slide 57

References

Purwadhika
Digital Technology School

https://medium.com/data-folks-indonesia/recommendation-system-dengan-python-definisi-part-1-71154dc3f700

https://towardsdatascience.com/introduction-to-two-approaches-of-content-based-recommendation-system-fc797460c18c

https://developers.google.com/machine-learning/recommendation/collaborative/basics

https://developers.google.com/machine-learning/recommendation/collaborative/matrix

https://realpython.com/build-recommendation-engine-collaborative-filtering/#:~:text=Collaborative%20filtering%20is%20a%20family,type%20of%20collaborative%20filtering%20approach.

Slide 58

References

Purwadhika
Digital Technology School

